

LAB03 Dallo stimatore Monte Carlo ai metodi MCMC

Antonio Scala

24 Marzo 2026

Obiettivi del laboratorio

In questo laboratorio useremo simulazioni numeriche per collegare in modo esplicito il Monte Carlo diretto visto nel laboratorio precedente con i metodi Markov Chain Monte Carlo introdotti nella lezione sulle catene di Markov e sull'algoritmo di Metropolis.

L'obiettivo non è solo implementare una catena corretta, ma capire:

1. come stimare la stessa quantità con tre strategie diverse;
2. perché il campionamento MCMC usa campioni correlati e non indipendenti;
3. che cosa significano, in pratica, burn-in, frequenza di accettazione e autocorrelazione;
4. quando una catena formalmente corretta può essere numericamente inefficiente;
5. perché, nel caso di un peso di Boltzmann, conviene usare direttamente ΔE nella regola di accettazione.

Confronteremo tre modi di stimare la stessa media:

1. integrazione numerica diretta su griglia;
2. Monte Carlo diretto con campioni indipendenti;
3. campionamento MCMC con algoritmo di Metropolis.

Nella parte finale discuteremo anche come misurare la correlazione temporale e come calcolarla in modo efficiente usando la FFT.

Struttura del laboratorio

Il laboratorio è diviso in cinque parti:

- Parte 0 – richiamo teorico e notazioni;
- Parte A – la stessa media con tre metodi;
- Parte B – Metropolis in forma di Boltzmann: rapporto vs ΔE ;

- Parte C – burn-in, correlazione e autocorrelazione;
- Parte D – effetto della scala di proposta;
- Microappendice – correlazione via FFT.

Parte 0 – Richiamo teorico

0.1 Dal laboratorio precedente

Nel laboratorio sui metodi Monte Carlo abbiamo già visto che una quantità del tipo

$$\langle O \rangle_p = \int O(x) p(x) dx$$

può essere stimata come media campionaria se sappiamo generare campioni indipendenti da $p(x)$.

Nel caso di una media con peso di Boltzmann, si scrive

$$\langle O \rangle = \frac{\int O(x) e^{-\beta E(x)} dx}{\int e^{-\beta E(x)} dx}.$$

Nel laboratorio precedente questa quantità veniva stimata separando numeratore e denominatore.

0.2 Passaggio a MCMC

Se non sappiamo campionare direttamente da

$$\pi(x) = \frac{1}{Z} e^{-\beta E(x)},$$

possiamo costruire una catena di Markov che abbia π come distribuzione stazionaria.

Se la catena è ergodica, allora per una osservabile O vale il principio ergodico:

$$\langle O \rangle_\pi \approx \frac{1}{N} \sum_{t=1}^N O(X_t), \quad X_t \sim \text{catena MCMC}.$$

Questa stima usa però campioni successivi che, in generale, non sono indipendenti.

0.3 Correlazione temporale: idea di base

Se definiamo

$$O_t = O(X_t),$$

una quantità naturale da studiare è la funzione di correlazione temporale non centrata

$$C(\tau) = \langle O_{t+\tau} O_t \rangle.$$

Empiricamente, su una traiettoria finita di lunghezza N , la stimiamo come

$$C(\tau) \approx \frac{1}{N-\tau} \sum_{t=0}^{N-\tau-1} O_{t+\tau} O_t.$$

Interpretazione:

- se $C(\tau)$ decade lentamente, la catena conserva memoria a lungo;
- se $C(\tau)$ decade rapidamente, i campioni diventano presto quasi indipendenti.

Se vogliamo una correlazione che, in un sistema ergodico, decada a zero per tempi lunghi, dobbiamo sottrarre il contributo delle medie:

$$C_{\text{conn}}(\tau) = \langle O_{t+\tau} O_t \rangle - \langle O_{t+\tau} \rangle \langle O_t \rangle.$$

In regime stazionario la media è invariante per traslazione temporale, quindi

$$\langle O_{t+\tau} \rangle = \langle O_t \rangle = \langle O \rangle,$$

e allora

$$C_{\text{conn}}(\tau) = \langle O_{t+\tau} O_t \rangle - \langle O \rangle^2.$$

Se poi vogliamo una funzione normalizzata tra 0 e 1, basta dividere per il valore a tempo zero:

$$\tilde{C}(\tau) = \frac{C(\tau)}{C(0)} \quad \text{oppure} \quad \tilde{C}_{\text{conn}}(\tau) = \frac{C_{\text{conn}}(\tau)}{C_{\text{conn}}(0)}.$$

In questo modo si può leggere, ad esempio, un tempo caratteristico dal punto in cui la correlazione scende sotto $1/e$.

0.4 Snippet Python: correlazione non centrata

```
import numpy as np

def corr_noncentrata(O, tau_max):
    O = np.asarray(O, dtype=float) # trasforma in un array per usare numpy
    N = len(O)
    C = np.empty(tau_max + 1) # le correlazioni andranno qui

    for tau in range(tau_max + 1):
        C[tau] = np.mean(O[:N - tau] * O[tau:])

    return C
```

0.5 Snippet Python: correlazione centrata e normalizzata

```
import numpy as np

def corr_centrata_normalizzata(O, tau_max):
    O = np.asarray(O, dtype=float)
    m = np.mean(O)
    X = O - m
    N = len(X)
    C = np.empty(tau_max + 1)

    for tau in range(tau_max + 1):
        C[tau] = np.mean(X[:N - tau] * X[tau:])

    return C / C[0]
```

Il problema di partenza

Useremo come distribuzione target un peso di Boltzmann del tipo

$$\pi(x) = \frac{1}{Z} e^{-\beta E(x)},$$

con energia

$$E(x) = \frac{x^4}{4} - \frac{x^2}{2}.$$

Questa scelta è utile perché:

1. si collega direttamente al laboratorio precedente;
2. consente integrazione numerica su griglia;

3. consente Monte Carlo diretto su un intervallo finito;
4. consente MCMC tramite Metropolis;
5. la forma della regola di accettazione può essere scritta direttamente in termini di ΔE .

Come osservabile principale useremo

$$O(x) = x^2.$$

Vogliamo quindi stimare

$$\langle O \rangle_\pi = \frac{\int O(x) e^{-\beta E(x)} dx}{\int e^{-\beta E(x)} dx}.$$

Nel seguito si può prendere, ad esempio,

$$\beta = 2.$$

Per la parte numerica si lavora su un intervallo finito simmetrico $[-L, L]$, con L abbastanza grande da rendere trascurabile il contributo delle code.

Parte A – La stessa media con tre metodi

A1. Metodo (i): integrazione numerica diretta su griglia

Stimare numericamente

$$A = \int_{-L}^L O(x) e^{-\beta E(x)} dx, \quad Z = \int_{-L}^L e^{-\beta E(x)} dx,$$

e poi costruire

$$\langle O \rangle_\pi = \frac{A}{Z}.$$

Usare una griglia uniforme e una regola numerica semplice, ad esempio trapezi o somma di Riemann.

Compiti

1. Scegliere un valore di L ragionevole e motivarlo.
2. Calcolare $\hat{A}_{\text{grid}}$, $\hat{Z}_{\text{grid}}$ e il rapporto.
3. Verificare quanto cambia il risultato raffinando la griglia.

A2. Metodo (ii): Monte Carlo diretto con campioni indipendenti

Campionare punti uniformi

$$X_i \sim \text{Unif}([-L, L]),$$

e stimare separatamente

$$\hat{A}_{\text{MC}} = \frac{2L}{N} \sum_{i=1}^N O(X_i) e^{-\beta E(X_i)},$$

$$\hat{Z}_{\text{MC}} = \frac{2L}{N} \sum_{i=1}^N e^{-\beta E(X_i)},$$

quindi

$$\widehat{\langle O \rangle}_{\text{MC}} = \frac{\hat{A}_{\text{MC}}}{\hat{Z}_{\text{MC}}}.$$

Compiti

1. Implementare lo stimatore Monte Carlo diretto.
2. Ripetere il calcolo per più valori di N .
3. Confrontare il risultato con l'integrazione numerica diretta.

A3. Metodo (iii): Metropolis MCMC

Costruire una catena con target

$$\pi(x) \propto e^{-\beta E(x)}$$

usando una proposta random walk gaussiana

$$x' = x + \eta, \quad \eta \sim \mathcal{N}(0, \sigma^2).$$

La stima dell'osservabile è

$$\widehat{\langle O \rangle}_{\text{MCMC}} = \frac{1}{N_{\text{meas}}} \sum_{t=t_{\text{burn}}+1}^N O(X_t).$$

Compiti

1. Implementare uno scheletro di Metropolis.
2. Usare burn-in esplicito.
3. Stimare $\langle O \rangle_\pi$.
4. Confrontare il risultato con i metodi (i) e (ii).

A4. Domande guida

1. I tre metodi convergono allo stesso valore?
2. Quale metodo è più semplice in una dimensione?
3. Quale metodo si generalizza meglio a dimensione più alta?
4. Quale metodo non richiede di conoscere Z ?

A5. Pseudocodice: tre approcci

Metodo (i): griglia

- scegli griglia x_k su $[-L, L]$
- calcola $A = \text{somma } 0(x_k) \exp(-\beta E(x_k)) \, dx$
- calcola $Z = \text{somma } \exp(-\beta E(x_k)) \, dx$
- restituisci A/Z

Metodo (ii): Monte Carlo diretto

- genera X_i uniformi in $[-L, L]$
- stima A e Z come medie campionarie
- restituisci A/Z

Metodo (iii): MCMC

- inizializza x_0
- esegui burn-in
- accumula $0(X_t)$ lungo la traiettoria
- restituisci la media temporale

Parte B – Metropolis in forma di Boltzmann: rapporto vs ΔE

B1. Regola di accettazione

Per il target

$$\pi(x) \propto e^{-\beta E(x)},$$

la regola di Metropolis può essere scritta in due modi equivalenti.

Forma 1: rapporto diretto

$$A(x \rightarrow x') = \min \left(1, \frac{e^{-\beta E(x')}}{e^{-\beta E(x)}} \right).$$

Forma 2: differenza di energia

Definendo

$$\Delta E = E(x') - E(x),$$

si ottiene

$$A(x \rightarrow x') = \min (1, e^{-\beta \Delta E}).$$

Le due formule sono matematicamente equivalenti.

B2. Compiti

1. Implementare entrambe le versioni.
2. Verificare che producano la stessa statistica finale.
3. Misurare il tempo di esecuzione delle due implementazioni usando `time.perf_counter()` oppure `timeit`.
4. Discutere quale forma è più conveniente dal punto di vista computazionale.

B3. Snippet Python: misura del tempo

```
import time

t0 = time.perf_counter()
# esegui qui molte iterazioni del metodo
t1 = time.perf_counter()

print("tempo totale =", t1 - t0)
```

B4. Domande guida

1. Le due forme dell'accettazione danno gli stessi risultati?
 2. La forma con ΔE è più naturale fisicamente?
 3. La forma con ΔE è più efficiente o più stabile numericamente?
-

Parte C – Burn-in, correlazione e medie cumulative

C1. Burn-in

Una catena MCMC non parte, in generale, dalla distribuzione di equilibrio. I primi passi dipendono dalla condizione iniziale e devono spesso essere scartati.

Esperimento

Lanciare tre catene con condizioni iniziali diverse, ad esempio

$$x_0 = -3, \quad x_0 = 0, \quad x_0 = 3.$$

Per ciascuna catena:

1. tracciare il trace plot di x_t ;
2. tracciare il trace plot di $O_t = x_t^2$;
3. tracciare la media cumulativa

$$M_n = \frac{1}{n} \sum_{t=1}^n O_t.$$

Domande guida

1. Le tre catene convergono alla stessa statistica?
2. Dopo quanti passi la media cumulativa sembra stabilizzarsi?
3. Quanto cambia la stima se si scartano i primi n_{burn} passi?

C2. Correlazione temporale

Usare l'osservabile

$$O_t = X_t^2$$

oppure

$$O_t = X_t.$$

Calcolare la correlazione non centrata

$$C(\tau) = \langle O_{t+\tau} O_t \rangle$$

tramite la formula empirica

$$C(\tau) \approx \frac{1}{N-\tau} \sum_{t=0}^{N-\tau-1} O_{t+\tau} O_t.$$

Poi, se si vuole una correlazione che tenda a zero in un sistema ergodico, passare alla forma centrata

$$C_{\text{conn}}(\tau) = \langle O_{t+\tau} O_t \rangle - \langle O \rangle^2.$$

Infine, se si vuole una funzione normalizzata tra 0 e 1, dividere per il valore a tempo zero.

Compiti

1. Calcolare $C(\tau)$ per $\tau = 0, 1, \dots, \tau_{\text{max}}$.
2. Calcolare anche la versione centrata e normalizzata.
3. Confrontare il decadimento della correlazione per diverse scelte della scala di proposta.

Domande guida

1. La correlazione decade rapidamente o lentamente?
2. Quanto dipende dalla scala di proposta?
3. Una catena con alta accettazione ha necessariamente correlazione più bassa?

Parte D – Effetto della scala di proposta

D1. Idea

Nel random walk Metropolis la proposta è

$$x' = x + \eta, \quad \eta \sim \mathcal{N}(0, \sigma^2).$$

La scelta di σ controlla il compromesso tra:

- frequenza di accettazione;
- esplorazione dello spazio degli stati;
- correlazione tra campioni successivi.

D2. Esperimento

Confrontare almeno tre valori di σ , ad esempio

$$\sigma = 0.1, \quad \sigma = 0.8, \quad \sigma = 2.5.$$

Per ciascun valore:

1. generare una traiettoria;
2. misurare la frequenza di accettazione;
3. plottare il trace plot;
4. calcolare $C(\tau)$;
5. stimare $\langle O \rangle_\pi$.

D3. Cosa aspettarsi

- proposta troppo piccola:
 - accettazione alta;
 - movimento lento;
 - correlazione forte;
- proposta intermedia:
 - buon compromesso;
 - correlazione più breve;
- proposta troppo grande:
 - molte proposte rifiutate;
 - catena quasi bloccata;
 - accettazione bassa.

D4. Domande guida

1. Quale valore di σ produce la stima più affidabile a parità di tempo computazionale?
2. Il miglior valore di σ è quello con accettazione più alta?
3. Come cambia il decadimento di $C(\tau)$ passando da una proposta troppo piccola a una troppo grande?

Parte E – Bonus opzionale: Gibbs sampling

Questa parte è opzionale e serve come confronto concettuale con Metropolis.

Considerare una gaussiana bidimensionale correlata

$$\pi(x_1, x_2) \propto \exp \left[-\frac{x_1^2 - 2\rho x_1 x_2 + x_2^2}{2(1 - \rho^2)} \right].$$

Le condizionate sono gaussiane:

$$x_1 \mid x_2 \sim \mathcal{N}(\rho x_2, 1 - \rho^2), \quad x_2 \mid x_1 \sim \mathcal{N}(\rho x_1, 1 - \rho^2).$$

Un passo di Gibbs consiste in:

$$x_1^{(t+1)} \sim \pi(x_1 \mid x_2^{(t)}), \quad x_2^{(t+1)} \sim \pi(x_2 \mid x_1^{(t+1)}).$$

Domande guida

1. Perché Gibbs non ha rifiuti?
 2. Che cosa richiede in più rispetto a Metropolis?
 3. In quale senso è più strutturato ma meno generale?
-

Materiale di partenza

Per il laboratorio si suggerisce di partire da tre script:

- 01_grid_vs_direct_mc.py
- 02_metropolis_boltzmann.py
- 03_correlation_and_diagnostics.py

eventualmente con un quarto file opzionale:

- 04_gibbs_bonus.py

Consegna

Ogni gruppo deve produrre:

1. il confronto tra i tre metodi di stima della stessa media;
2. una verifica che la forma con rapporto e la forma con ΔE danno la stessa statistica;
3. una misura dei tempi di esecuzione delle due implementazioni;
4. un trace plot che mostri il burn-in;
5. almeno un grafico di correlazione $C(\tau)$;
6. un confronto tra almeno tre scale di proposta;
7. un breve commento finale sui punti seguenti:
 - differenza tra Monte Carlo diretto e MCMC;
 - ruolo del burn-in;
 - significato della correlazione temporale;
 - correttezza teorica vs efficienza pratica.

Checklist finale

1. Stima di $\langle O \rangle_\pi$ con:
 - griglia,
 - Monte Carlo diretto,
 - MM.
 2. Confronto tra forma con rapporto e forma con ΔE .
 3. Diagnostica di burn-in e media cumulativa.
 4. Calcolo della correlazione non centrata.
 5. Versione centrata/normalizzata della correlazione.
 6. Confronto tra diverse scale di proposta.
-

Microappendice – Calcolo veloce della correlazione con FFT

La correlazione discreta può essere vista come una convoluzione.

Per una sequenza O_t , la quantità

$$C(\tau) \sim \sum_t O_{t+\tau} O_t$$

ha struttura di convoluzione tra la sequenza e la sequenza ribaltata.

Poiché la trasformata di Fourier trasforma una convoluzione in un prodotto, il calcolo della correlazione può essere accelerato usando la FFT:

$$\mathcal{F}[f * g] = \mathcal{F}[f]; \mathcal{F}[g].$$

Nel caso centrato, se definiamo

$$X_t = O_t - \langle O \rangle,$$

allora schematicamente

$$C_{\text{conn}}(\tau) = \mathcal{F}^{-1}!(\mathcal{F}[X]; \mathcal{F}[X]^*),$$

dove $*$ indica il complesso coniugato.

Questo riduce il costo computazionale da circa N^2 a circa $N \log N$.

Snippet Python con FFT

```
import numpy as np

def corr_fft_centrata(O):
    O = np.asarray(O, dtype=float)
    X = O - np.mean(O)
    N = len(X)

    nfft = 2 * N
    F = np.fft.rfft(X, n=nfft)
    S = F * np.conjugate(F)
    C = np.fft.irfft(S, n=nfft)[:N]

    C /= np.arange(N, 0, -1)
    return C
```

Versione normalizzata

```
def corr_fft_centrata_normalizzata(O):
    C = corr_fft_centrata(O)
    return C / C[0]
```

Domanda finale

Quando conviene usare la FFT invece del calcolo diretto della correlazione?