

04a: Entropia, logaritmi e massima entropia

Antonio Scala

1. Perché compare il logaritmo?

In molti contesti – dalla fisica alla statistica – compaiono espressioni del tipo

$$\log p \quad \text{oppure} \quad e^{-x}.$$

Una domanda naturale è: perché lavorare con logaritmi o esponenziali invece che direttamente con le probabilità?

La risposta di base è che il logaritmo trasforma prodotti in somme.

Se eventi indipendenti hanno probabilità $p_1, p_2, \dots, p_n$, allora

$$P = \prod_{i=1}^n p_i,$$

mentre

$$\log P = \sum_{i=1}^n \log p_i.$$

Questo rende il logaritmo particolarmente naturale quando si combinano molti contributi elementari.

Ma c'è anche un'altra ragione importante: il logaritmo permette di quantificare la **sorpresa** associata a un evento.

2. Sorpresa matematica e informazione

Se un evento ha probabilità p , è naturale dire che esso è tanto più “sorprendente” quanto più p è piccolo.

Una misura quantitativa semplice e molto utile della sorpresa è

$$I(p) = \log \frac{1}{p} = -\log p.$$

Questa funzione ha proprietà desiderabili:

1. se un evento è molto probabile (p vicino a 1), la sorpresa è piccola;

2. se un evento è raro (p piccolo), la sorpresa è grande;
3. per eventi indipendenti la sorpresa totale è additiva:

$$I(p_1 p_2) = -\log(p_1 p_2) = -\log p_1 - \log p_2 = I(p_1) + I(p_2).$$

Questa quantità è spesso chiamata **self-information** o **informazione di sorpresa**.

La scelta del logaritmo non è quindi arbitraria: è ciò che rende l'informazione additiva per eventi indipendenti.

3. Informazione di Shannon

Shannon formalizza questa idea definendo l'informazione associata a un evento i di probabilità p_i come

$$I_i = -\log p_i.$$

Questa definizione traduce in linguaggio matematico l'idea intuitiva che:

- eventi comuni portano poca informazione;
- eventi rari portano molta informazione.

Ad esempio, sapere che domani il Sole sorgerà contiene pochissima informazione; sapere che vincerò alla lotteria ne contiene molta di più.

4. Entropia come sorpresa media

Se una variabile casuale assume valori i con probabilità p_i , la sorpresa media è

$$H = \sum_i p_i I_i = - \sum_i p_i \log p_i.$$

Questa è l'**entropia di Shannon**.

Interpretazione:

- misura l'incertezza media prima di osservare il risultato;
- è massima quando tutti gli esiti sono equiprobabili;
- è minima quando un esito è certo.

Quindi l'entropia non misura la sorpresa di un singolo evento, ma la **sorpresa media attesa** del sistema.

5. Perché proprio il logaritmo?

Il logaritmo non è una scelta decorativa o puramente tecnica.

È la funzione naturale quando vogliamo una quantità che:

- cresca al diminuire della probabilità;

- sia nulla per un evento certo;
- sia additiva per eventi indipendenti.

In questo senso, il logaritmo costruisce un ponte tra:

- probabilità;
- informazione;
- entropia;
- likelihood.

6. Da Shannon a Boltzmann–Gibbs

In meccanica statistica, l'entropia si scrive

$$S = -k_B \sum_i p_i \ln p_i.$$

Questa formula è formalmente identica a quella di Shannon, a meno della costante k_B .

Qui il logaritmo ha una doppia interpretazione:

- informazionale: misura incertezza o sorpresa media;
- fisica: codifica il numero effettivo di microstati compatibili con lo stato macroscopico.

La parentela tra entropia fisica e informazione non è quindi accidentale.

7. Massima entropia

Il principio di **massima entropia** (Jaynes) afferma:

tra tutte le distribuzioni compatibili con i vincoli noti, si sceglie quella con entropia massima.

L'idea è che non dobbiamo introdurre struttura o informazione non giustificata dai dati disponibili.

Se conosco solo alcuni vincoli globali, la distribuzione più “onesta” è quella che resta il più possibile indeterminata pur rispettando quei vincoli.

In molti casi, questo principio porta naturalmente a distribuzioni esponenziali.

8. Likelihood e log-likelihood

In statistica, dati indipendenti $x_1, \dots, x_n$ generati da un modello con parametro θ hanno likelihood

$$L(\theta) = \prod_{i=1}^n p(x_i \mid \theta).$$

Si lavora quasi sempre con la **log-likelihood**:

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log p(x_i \mid \theta).$$

Anche qui il logaritmo appare perché rende additive quantità che, a livello probabilistico, nascono come prodotti.

9. Perché la log-likelihood è utile

La log-likelihood è preferita perché:

- trasforma prodotti in somme;
- è numericamente più stabile;
- semplifica derivate e ottimizzazione;
- rende evidente il contributo di ogni osservazione.

Inoltre, massimizzare la likelihood equivale a massimizzare la log-likelihood, perché il logaritmo è monotono crescente.

Questa è una delle ragioni per cui il logaritmo compare così spesso anche fuori dalla fisica statistica.

10. Collegamento concettuale

Entropia e log-likelihood sono profondamente collegate.

- la sorpresa di un singolo evento è $-\log p$;
- l'entropia è la media di $-\log p$;
- la log-likelihood è una somma di termini $\log p$.

In tutti questi casi, il logaritmo rende **additiva** una quantità fondamentale.

11. Messaggio finale

Il logaritmo compare in molti ambiti perché:

- rende additive quantità moltiplicative;
- misura la sorpresa matematica di un evento;
- permette di definire l'informazione e l'entropia;
- semplifica l'analisi statistica tramite la log-likelihood;
- emerge naturalmente dal principio di massima entropia.

Non è quindi una scelta tecnica arbitraria, ma una struttura molto generale dei sistemi probabilistici.

Appendice – Un esempio semplice di massima entropia con moltiplicatori di Lagrange

Mostriamo ora, in forma elementare, come il principio di Jaynes conduca a una distribuzione esponenziale.

Per evitare complicazioni funzionali, consideriamo un insieme **finito** di valori possibili

$$x_1, x_2, \dots, x_n$$

e cerchiamo le probabilità

$$p_1, p_2, \dots, p_n$$

che massimizzano l'entropia

$$H = - \sum_{i=1}^n p_i \log p_i$$

sotto i vincoli

$$\sum_{i=1}^n p_i = 1$$

(normalizzazione) e

$$\sum_{i=1}^n p_i x_i = m,$$

dove m è il valore medio assegnato (o, in casi concreti, osservato/misurato).

A.1 Richiamo: metodo dei moltiplicatori di Lagrange

Se vogliamo massimizzare una funzione $f(x_1, \dots, x_n)$ sotto vincoli

$$g_1(x_1, \dots, x_n) = 0, \quad g_2(x_1, \dots, x_n) = 0,$$

introduciamo una funzione ausiliaria

$$\mathcal{L} = f + \lambda_1 g_1 + \lambda_2 g_2$$

e imponiamo che tutte le derivate parziali rispetto alle variabili e ai moltiplicatori siano nulle.

Qui le variabili sono le probabilità p_i , e i vincoli sono la normalizzazione e il valore medio fissato.

A.2 Costruzione della lagrangiana

Definiamo

$$\mathcal{L}(p_1, \dots, p_n, \alpha, \beta) = - \sum_{i=1}^n p_i \log p_i - \alpha \left(\sum_{i=1}^n p_i - 1 \right) - \beta \left(\sum_{i=1}^n p_i x_i - m \right).$$

I segni davanti ad α e β sono convenzionali: cambierebbe solo la notazione finale.

A.3 Condizione di stazionarietà

Deriviamo rispetto a ciascun p_i :

$$\frac{\partial \mathcal{L}}{\partial p_i} = -(\log p_i + 1) - \alpha - \beta x_i.$$

Ponendo questa derivata uguale a zero otteniamo

$$-(\log p_i + 1) - \alpha - \beta x_i = 0,$$

cioè

$$\log p_i = -1 - \alpha - \beta x_i.$$

Esponenziando,

$$p_i = e^{-1-\alpha-\beta x_i}.$$

Le equazioni ottenute derivando rispetto ai moltiplicatori α e β restituiscono semplicemente i vincoli originali:

$$\sum_{i=1}^n p_i = 1, \quad \sum_{i=1}^n p_i x_i = m.$$

Nel seguito usiamo il primo per determinare la costante di normalizzazione e il secondo per fissare il valore di β .

A.4 Determinazione della costante

Possiamo riscrivere il prefattore costante come una nuova costante di normalizzazione:

$$p_i = C e^{-\beta x_i};$$

usando il vincolo di normalizzazione:

$$\sum_{i=1}^n p_i = 1 \quad \Rightarrow \quad C \sum_{i=1}^n e^{-\beta x_i} = 1.$$

Quindi

$$C = \frac{1}{Z(\beta)}, \quad Z(\beta) = \sum_{i=1}^n e^{-\beta x_i}.$$

La distribuzione finale è dunque

$$p_i = \frac{e^{-\beta x_i}}{Z(\beta)}.$$

Il parametro β va poi scelto in modo che sia soddisfatto il vincolo sul valore medio

$$\sum_{i=1}^n x_i p_i = m.$$

Sostituendo la forma trovata per p_i ,

$$p_i = \frac{e^{-\beta x_i}}{Z(\beta)}, \quad Z(\beta) = \sum_{i=1}^n e^{-\beta x_i},$$

si ottiene una relazione che lega β al valore medio:

$$\sum_{i=1}^n x_i \frac{e^{-\beta x_i}}{Z(\beta)} = m.$$

Questa è un'equazione per β , che in generale non si risolve in forma esplicita, ma può essere risolta numericamente (ad esempio con metodi iterativi).

In modo equivalente, si può osservare che

$$\langle x \rangle = -\frac{d}{d\beta} \log Z(\beta),$$

quindi β è determinato imponendo che questa quantità sia uguale a m .

A.5 Interpretazione

Abbiamo ottenuto una distribuzione esponenziale non perché l'abbiamo ipotizzata, ma perché è la soluzione del problema:

- massimizzare l'incertezza;
- mantenendo fissati solo normalizzazione e valore medio.

Questa è l'idea centrale del principio di Jaynes.

In meccanica statistica, se x_i viene interpretata come energia E_i , si ottiene la distribuzione di Boltzmann:

$$p_i = \frac{e^{-\beta E_i}}{Z(\beta)}.$$

A.6 Take home message

Questo esempio mostra tre idee importanti:

1. il logaritmo compare naturalmente nell'entropia;
2. l'esponenziale compare naturalmente come soluzione del problema di massimo;
3. i moltiplicatori di Lagrange permettono di incorporare i vincoli in modo sistematico.

Per questo entropia, logaritmi ed esponenziali tendono a comparire insieme in molti contesti diversi.