

S02 Metodi Monte Carlo

Antonio Scala

11 mar 2026

Obiettivi della lezione

Obiettivi didattici specifici

Al termine della lezione lo studente dovrà essere in grado di:

- ▶ comprendere il principio dei metodi Monte Carlo
- ▶ interpretare Monte Carlo come stima di una media
- ▶ distinguere errore statistico ed errore sistematico
- ▶ comprendere perché Monte Carlo è utile in alta dimensione
- ▶ generare campioni da distribuzioni assegnate
- ▶ comprendere il ruolo del campionamento nelle simulazioni

Idea centrale

Sostituire un calcolo deterministico con una **media statistica su campioni casuali**.

Origine dei metodi Monte Carlo

Breve contesto storico

- ▶ sviluppati negli anni 40
- ▶ coinvolti:
 - ▶ **Stanislaw Ulam**
 - ▶ **John von Neumann**
 - ▶ **Nicholas Metropolis**

Applicazioni iniziali:

- ▶ trasporto neutronico
- ▶ problemi di fisica nucleare
- ▶ simulazioni statistiche

Il nome deriva dal **casino di Monte Carlo**.

Monte Carlo come stima di una media

Principio generale

Sia X una variabile aleatoria con densità $p(x)$.

Il valore atteso di una funzione $f(x)$ è

$$\langle f(X) \rangle = \int f(x)p(x) dx$$

Stima Monte Carlo:

$$\langle f(X) \rangle \approx \frac{1}{N} \sum_{i=1}^N f(x_i)$$

dove $x_i \sim p(x)$.

Legge dei grandi numeri

Convergenza della media campionaria

Se x_i sono campioni indipendenti:

$$\bar{f}_N = \frac{1}{N} \sum_{i=1}^N f(x_i)$$

allora

$$\bar{f}_N \rightarrow \langle f \rangle \quad (N \rightarrow \infty)$$

Errore statistico

$$\sigma \sim \frac{1}{\sqrt{N}}$$

Dal teorema del limite centrale: convergenza lenta ma universale.

Errore statistico vs errore sistematico

Errore statistico

Deriva dal numero finito di campioni.

Caratteristiche:

- ▶ fluttuazioni casuali
- ▶ decresce come $1/\sqrt{N}$
- ▶ stimabile dai dati

Errore sistematico

Deriva da:

- ▶ generatore pseudocasuale di bassa qualità
- ▶ campionamento non coerente con $p(x)$
- ▶ trasformazioni numericamente instabili
- ▶ correlazioni indesiderate tra campioni

Non scompare aumentando N .

Perché Monte Carlo è importante

Il problema della dimensione

Molti problemi richiedono integrali:

$$I = \int_{\Omega} f(\mathbf{x}) d\mathbf{x}$$


con $\mathbf{x} \in \mathbb{R}^d$. Nei metodi deterministici:
numero di punti $\sim n^d$.

Monte Carlo

Errore (sempre limite centrale della media):

$$\sigma \sim \frac{1}{\sqrt{N}}$$

dipende solo da N , è indipendente da d .



Interpretazione geometrica


Stima di π

- Genera punti uniformi nel quadrato unitario.
- Conta quelli nel quarto di cerchio:

$$x^2 + y^2 \leq 1$$

$$\pi \approx 4 \frac{N_{in}}{N}$$

Interpretazione:
probabilità = rapporto tra aree.



Numero effettivo di campioni

Non tutti i campioni contribuiscono allo stesso modo.

Definizione intuitiva:

- ▶ campioni altamente correlati
- ▶ campioni con peso molto diverso

⇒ informazione ridotta.

Si introduce spesso:

numero **effettivo di campioni**

$$N_{\text{eff}} = \frac{N}{\tau} < N$$

dove τ è la lunghezza di correlazione caratteristica.

Il problema delle regioni rare

Funzioni molto concentrate

In molti problemi:

- ▶ la maggior parte dello spazio contribuisce poco
- ▶ regioni piccole dominano l'integrale

Campionamento uniforme $\Rightarrow$ inefficiente, varianza enorme.

Esempi:

- ▶ barriere energetiche
- ▶ eventi rari
- ▶ code di distribuzioni

Soluzione naturale: concentrare i campioni dove serve.

$\Rightarrow$ **importance sampling**

Generazione di numeri pseudocasuali

Generatori

Un generatore produce numeri uniformi

$$U \in [0, 1)$$

sequenza **deterministica** con proprietà statistiche buone.

Esempi:

- ▶ generatori congruenziali lineari
- ▶ Mersenne Twister
- ▶ PCG

Perché il determinismo è accettabile

Non serve casualità ontologica: basta che la sequenza si comporti **come se** fosse indipendente e uniforme rispetto alle osservabili di interesse.

Riproducibilità e seed

Il valore iniziale

Ogni generatore è inizializzato da un valore detto **seed**.

Vantaggi pratici:

- ▶ la simulazione è **riproducibile**
- ▶ si possono confrontare algoritmi a parità di sequenza
- ▶ il debugging è controllabile

Fissare il seed non riduce la qualità statistica: cambia solo il punto di partenza nella sequenza.

Attenzione

Sequenze con seed diversi producono risultati statisticamente equivalenti, ma numericamente diversi.

Metodo dell'inversione

Idea

Se $F(x)$ è la CDF:

$$F(x) = P(X \leq x)$$

e $U \sim \text{Unif}(0, 1)$,
definiamo

$$X = F^{-1}(U)$$

$\Rightarrow X$ ha distribuzione $p(x) = F'(x)$.

Perché funziona

Dimostrazione (caso continuo)

Poiché F è crescente, $F^{-1}(U) \leq x$ equivale a $U \leq F(x)$.



Quindi:

$$P(X \leq x) = P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F(x)$$

L'ultima uguaglianza vale perché U è uniforme in $[0, 1)$.

La variabile $X = F^{-1}(U)$ ha quindi esattamente la distribuzione F .

Distribuzione discreta e CDF



Caso generale: inversa generalizzata

Distribuzioni discrete o miste

Quando F non è strettamente crescente (tratti piatti, salti), l'inversa classica non esiste.

Si definisce la **funzione quantile**:

$$F^{-1}(u) = \inf \{ x \in \mathbb{R} : F(x) \geq u \}, \quad u \in (0, 1)$$

Vale ancora:

$$P(X \leq x) = P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F(x)$$

La proprietà fondamentale è preservata anche nel caso discreto.

Inversa generalizzata: note pratiche

Quando usarla

- ▶ distribuzioni discrete (Poisson, binomiale, ...)
- ▶ distribuzioni miste (parte continua + massa puntuale)
- ▶ CDF definita per tabulazione

Implementazione

Quando F^{-1} non ha forma chiusa:

- ▶ tabulazione e interpolazione monotona
- ▶ bisezione o metodo di Newton su F
- ▶ evitare U troppo vicino a 0 o 1 (instabilità nelle code)

Esempio: distribuzione esponenziale

Distribuzione:

$$p(x) = \lambda e^{-\lambda x}$$

CDF:

$$F(x) = 1 - e^{-\lambda x}$$

Metodo dell'inversione:

$$X = -\frac{1}{\lambda} \ln U$$

(poiché U e $1 - U$ hanno la stessa distribuzione uniforme)

Limiti del metodo dell'inversione

Problemi pratici

Richiede:

- ▶ CDF invertibile in forma chiusa o numericamente stabile
- ▶ inversione efficiente

Molte distribuzioni importanti:

- ▶ non hanno forma chiusa (gaussiana, beta, gamma. . .)
- ▶ richiedono metodi alternativi

Nel caso multidimensionale: costruire trasformazioni congiunte compatibili con l'intera distribuzione è raramente conveniente.

Metodo di accettazione-rifiuto

Idea

Usiamo una distribuzione ausiliaria $g(x)$.


Condizione:

$$p(x) \leq c g(x)$$

Algoritmo:

1. genera $x \sim g(x)$
2. genera $u \sim U(0, 1)$
3. accetta se

$$u < \frac{p(x)}{c g(x)}$$



Interpretazione geometrica

Accept-reject

Campionamento uniforme sotto la curva

$$c g(x)$$

Accetta solo i punti sotto $p(x)$.

Efficienza:

$$\text{efficienza} = \frac{1}{c}$$

Scegliere $g(x)$ vicino a $p(x)$ riduce gli scarti e aumenta la produttività del metodo.

Campionamento per importanza

Idea

Campionare non uniformemente.

Scriviamo

$$I = \int f(x) dx = \int \frac{f(x)}{q(x)} q(x) dx$$

Campioniamo da $q(x)$.

Stima:

$$I \approx \frac{1}{N} \sum_{i=1}^N \frac{f(x_i)}{q(x_i)}$$

Importance sampling


Perché campionare meglio

Campionamento uniforme:

- ▶ molti punti cadono in regioni poco rilevanti

Importance sampling:

- ▶ concentra i campioni dove $f(x)$ contribuisce di più



Scelta della distribuzione ausiliaria

Criterio ideale

La scelta ottimale sarebbe $q(x) \propto |f(x)|$: la varianza della stima si annulla.

In pratica si sceglie $q(x)$ tale che:

- ▶ sia facile da campionare
- ▶ approssimi la forma di $|f(x)|$
- ▶ non sia mai troppo piccola dove $f(x)$ è grande

Attenzione

Se $q(x)$ è molto piccola in regioni dove $f(x)$ è grande, i pesi $f(x)/q(x)$ esplodono
 $\Rightarrow$ stima instabile.

Osservabili e stime

Osservabili

In molte simulazioni vogliamo stimare:

$$\langle A \rangle = \int A(x) p(x) dx$$

Monte Carlo:

$$\langle A \rangle \approx \frac{1}{N} \sum_{i=1}^N A(x_i)$$

con $x_i \sim p(x)$.

Consistenza dello stimatore

Proprietà desiderate

Uno stimatore Monte Carlo dovrebbe essere:

- ▶ **non distorto:** $\mathbf{E}[\hat{A}_N] = \langle A \rangle$
- ▶ **consistente:** $\hat{A}_N \rightarrow \langle A \rangle$ per $N \rightarrow \infty$
- ▶ con varianza controllabile: $\text{Var}(\hat{A}_N) = \text{Var}(A)/N$

Il risultato di una simulazione non è un numero esatto, ma una **stima con incertezza controllabile**.

Tecniche di riduzione della varianza

Obiettivo

Ridurre l'incertezza **senza aumentare** N .

Campionamento stratificato

Suddividere Ω in strati di uguale misura, generare un campione in ciascuno.

Evita concentrazioni casuali in una zona sola.

Antithetic variates

Per ogni $u \in [0, 1)$ si usa anche $1 - u$.

Le due valutazioni di f tendono ad avere errori opposti: la media è più stabile.

Importance sampling

Già discusso: concentra i campioni nelle regioni rilevanti.

Covarianza e correlazione

Covarianza

Data due variabili X e Y , la covarianza misura se tendono a crescere insieme:

$$\text{Cov}(X, Y) = \mathbf{E}[(X - \mu_X)(Y - \mu_Y)]$$

- ▶ $\text{Cov} > 0$: crescono insieme
- ▶ $\text{Cov} < 0$: una cresce, l'altra decresce
- ▶ $\text{Cov} = 0$: non correlate (linearmente)

Limite: dipende dalle unità di misura di X e Y .

Coefficiente di correlazione di Pearson

Correlazione

Si normalizza la covarianza con le deviazioni standard:

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} \in [-1, 1]$$

- ▶ $\rho = 1$: dipendenza lineare perfetta positiva
- ▶ $\rho = -1$: dipendenza lineare perfetta negativa
- ▶ $\rho = 0$: nessuna dipendenza **lineare**

Attenzione

$\rho = 0$ non implica indipendenza. Due variabili possono essere fortemente dipendenti in modo non lineare e avere $\rho = 0$.

Correlazione di Kendall

Oltre la linearità

La correlazione di Pearson misura solo dipendenza lineare. La **correlazione di Kendall** τ_K misura la concordanza dei ranghi: due osservazioni (x_i, y_i) e (x_j, y_j) sono

- ▶ **concordanti** se $x_i > x_j$ e $y_i > y_j$ (o entrambe minori)
- ▶ **discordanti** altrimenti

$$\tau_K = \frac{\text{coppie concordanti} - \text{coppie discordanti}}{\text{coppie totali}}$$

Vantaggio

τ_K è invariante per trasformazioni monotone: se $U = F(X)$ con F crescente, $\tau_K(U, V) = \tau_K(X, Y)$.

Per questo è la misura naturale da usare con le copule.

Gaussiana multivariata

Distribuzione

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2}(\det \Sigma)^{1/2}} \exp \left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right]$$

dove Σ è la matrice di covarianza:

$$\Sigma_{ij} = \text{Cov}(X_i, X_j)$$

Σ deve essere simmetrica e semidefinita positiva.

Generazione tramite trasformazione lineare

Metodo

Se $\Sigma = LL^T$ è una matrice di covarianza e $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, I)$, allora

$$\mathbf{X} = \boldsymbol{\mu} + L\mathbf{z}$$

$\mathbf{X}$ ha media $\boldsymbol{\mu}$ e covarianza Σ .

Verifica

$$\text{Cov}(\mathbf{X}) = \mathbb{E}(\mathbf{X}\mathbf{X}^T) = L \mathbb{E}[\mathbf{z}\mathbf{z}^T] L^T = L I L^T = \Sigma$$

Fattorizzazione di Cholesky

Metodo standard

Se Σ è **strettamente definita positiva**:

$$\Sigma = LL^T$$

con L triangolare inferiore.

Vantaggi:

- ▶ stabile e veloce
- ▶ semplice da implementare

Limite:

- ▶ fallisce se Σ ha autovalori nulli o quasi nulli
- ▶ non applicabile a matrici singolari

Decomposizione spettrale

Alternativa generale

Diagonalizzazione di Σ :

$$\Sigma = Q\Lambda Q^T$$

con Q ortogonale, Λ diagonale con autovalori ≥ 0 .

Si pone:

$$L = Q\Lambda^{1/2}$$

Interpretazione geometrica


L ruota e dilata il vettore gaussiano isotropo, deformando la sfera unitaria in un **ellissoide** di covarianza Σ .

Funziona anche quando Σ è solo semidefinita positiva.


Campionamento gaussiano multivariato

Da isotropo a correlato

Gaussiana standard isotropa



Gaussiana correlata



Problemi numerici

Matrici mal condizionate

Nella pratica, Σ stimata dai dati può essere:

- ▶ quasi singolare (autovalori molto piccoli)
- ▶ numericamente non definita positiva
- ▶ singolare (distribuzioni degeneri)

Strategie

Regolarizzazione diagonale:

$$\Sigma_{\epsilon} = \Sigma + \epsilon I$$

sposta gli autovalori lontano da zero.

Troncamento spettrale: autovalori negativi o sotto soglia $\rightarrow$ posti a zero.

Pseudoinversa di Moore–Penrose

Quando Σ è singolare

L'inversa ordinaria non esiste o non è affidabile.

Dalla decomposizione spettrale $\Sigma = Q\Lambda Q^T$:

$$\Sigma^+ = Q\Lambda^+ Q^T$$

dove Λ^+ inverte solo gli autovalori **significativamente diversi da zero**.

Utilità

Permette di trattare distribuzioni gaussiane **degeneri**, concentrate su sottospazi di dimensione inferiore.

Esempio: dati con correlazioni esatte, variabili ridondanti.

Pseudoinversa come proiezione

Distribuzioni degeneri

Se Σ ha rango $r < d$, alcuni autovalori sono nulli: la distribuzione è concentrata su un **sottospazio di dimensione** r . Scriviamo la decomposizione ridotta:

$$\Sigma = Q_r \Lambda_r Q_r^T$$

dove $Q_r \in \mathbb{R}^{d \times r}$ contiene solo gli r autovettori significativi e Λ_r i corrispondenti autovalori positivi.

Generazione

Si campiona $\mathbf{Z}_r \in \mathbb{R}^r$ gaussiano standard, poi:

$$\mathbf{X} = \boldsymbol{\mu} + Q_r \Lambda_r^{1/2} \mathbf{Z}_r$$

$Q_r \Lambda_r^{1/2}$ **proietta** il campionamento sul sottospazio rilevante. Le direzioni a varianza nulla non vengono mai esplorate.

Oltre la dipendenza gaussiana: copule

Il problema

La covarianza non basta a descrivere la dipendenza tra variabili non gaussiane.

Due distribuzioni possono avere **stessa covarianza** ma dipendenze molto diverse:

- ▶ concordanza nelle situazioni normali
- ▶ comportamento opposto nelle code

Serve uno strumento più generale.

Copule: il teorema di Sklar

Separare marginali e dipendenza

Data $F(x_1, \dots, x_d)$ con marginali $F_1, \dots, F_d$, esiste una funzione $C : [0, 1]^d \rightarrow [0, 1]$ tale che

$$F(x_1, \dots, x_d) = C(F_1(x_1), \dots, F_d(x_d))$$

C è la **copula**: contiene tutta e sola la struttura di dipendenza.

Idea chiave

Se $U_i = F_i(X_i)$, allora $U_i \sim \text{Unif}(0, 1)$ per ogni i , ma $(U_1, \dots, U_d)$ non sono indipendenti.

La loro distribuzione congiunta è la copula.

Copule: simulazione e famiglie

Come simulare

1. generare $(u_1, \dots, u_d)$ dalla copula C
2. applicare le inverse: $x_i = F_i^{-1}(u_i)$

Le marginali F_i possono essere qualunque.

Famiglie principali


- ▶ **Gaussiana**: dipendenza gaussiana, marginali libere
- ▶ **Student**: come gaussiana ma code più pesanti; cattura concordanza negli eventi estremi
- ▶ **Archimedeo** (Clayton, Gumbel, Frank): asimmetria nella dipendenza tra coda inferiore e coda superiore

Applicazioni

Finanza (crolli correlati), attuariale, statistica multivariata con dati asimmetrici.

Copule: confronto visivo

Stessa dipendenza, pattern diversi



τ_K = correlazione di Kendall: versione robusta della correlazione

Cosa non è ancora Monte Carlo

Limiti della trattazione

In questa lezione:

- ▶ campionamento **indipendente**

Ma molti problemi richiedono:

- ▶ campionamento **correlato**
- ▶ distribuzioni definite implicitamente

Esempio:

$$p(x) \propto e^{-E(x)}$$

Collegamento con la prossima lezione

Catene di Markov

Quando non possiamo campionare direttamente:
costruiamo una **catena di Markov**
che abbia $p(x)$ come distribuzione stazionaria.

Algoritmi fondamentali:

- ▶ Metropolis
- ▶ Metropolis-Hastings
- ▶ Gibbs sampling

Base dei metodi **MCMC**.

Take-home messages

- ▶ Monte Carlo = stima di una media tramite campionamento
- ▶ errore statistico $\sim 1/\sqrt{N}$, errore sistematico non scompare con N
- ▶ efficiente in alta dimensione: costo indipendente da d
- ▶ inversione, accept-reject, importance sampling: strumenti complementari
- ▶ variabili correlate: Cholesky, spettrale, pseudoinversa per casi degeneri
- ▶ copule: separare marginali e dipendenza
- ▶ base per metodi più avanzati (MCMC)