

S03 Markov Chain Monte Carlo (MCMC)

Antonio Scala

18 mar 2026

Obiettivi della lezione

Idea centrale: Quando non possiamo campionare direttamente da $\pi(x)$, costruiamo una **dinamica artificiale** che abbia π come distribuzione di equilibrio.

Obiettivi:

- ▶ definire una catena di Markov e interpretare la matrice di transizione
- ▶ distinguere irriducibilità, aperiodicità ed ergodicità
- ▶ comprendere il ruolo della distribuzione stazionaria e del bilancio dettagliato
- ▶ spiegare perché i metodi MCMC sono utili quando il campionamento diretto fallisce
- ▶ derivare e applicare la regola di accettazione di Metropolis e Metropolis-Hastings
- ▶ riconoscere i principali problemi di efficienza (termalizzazione, autocorrelazione, metastabilità)

Da MC a MCMC


Nella lezione precedente:

- ▶ campionamento **indipendente** da $p(x)$ nota
- ▶ inversione, accept-reject, importance sampling

Ma molti problemi reali richiedono di campionare

$$\pi(x) \propto \tilde{\pi}(x)$$

con $\tilde{\pi}$ calcolabile ma $Z = \int \tilde{\pi} dx$ **intrattabile**.



*Campionamento diretto (indipendente)
vs traiettoria MCMC (correlata)*

Catene di Markov

Definizione

Una **catena di Markov** è una successione $X_0, X_1, X_2, \dots$ tale che


$$P(X_{t+1} = j \mid X_t = i, X_{t-1}, \dots) = P(X_{t+1} = j \mid X_t = i).$$

Il futuro dipende **solo dallo stato presente**, non dalla storia.

La matrice di transizione P raccoglie queste probabilità:

$$P_{ij} = P(X_{t+1} = j \mid X_t = i),$$

con $P_{ij} \geq 0$ e $\sum_j P_{ij} = 1$ per ogni i .



Grafo di una catena a tre stati con probabilità di transizione

Evoluzione della distribuzione


Se $\mu^{(t)}$ è la distribuzione al tempo t (vettore riga):

$$\mu^{(t+1)} = \mu^{(t)} P, \quad \mu^{(t)} = \mu^{(0)} P^t.$$

Il comportamento a lungo termine della catena coincide con lo studio delle potenze di P . In particolare, se la catena è finita, irriducibile e aperiodica,

$$\lim_{t \rightarrow \infty} \mu^{(0)} P^t = \pi,$$

dove π è la distribuzione di equilibrio, cioè il punto fisso $\pi P = \pi$.



Proprietà fondamentali

Irriducibilità e aperiodicità

Irriducibilità

Tutti gli stati comunicano: da ogni stato si può raggiungere ogni altro stato.

⇒ la catena può esplorare tutto lo spazio.

Aperiodicità


Lo stato i ha periodo

$$d(i) = \gcd\{n \geq 1 : (P^n)_{ii} > 0\}.$$


Se $d(i) = 1$ per tutti gli stati: la catena è **aperiodica**.

⇒ niente oscillazioni rigide, convergenza regolare.

Catena riducibile



Catena periodica (periodo 3)



Convergenza ed ergodicità

Convergenza all'equilibrio

Se la catena è finita, irriducibile e aperiodica, allora

$$\lim_{t \rightarrow \infty} \mu^{(0)} P^t = \pi,$$

dove π è la distribuzione di equilibrio, cioè il punto fisso

$$\pi P = \pi.$$

In questo caso la catena dimentica la condizione iniziale.

Ricorrenza e transienza

- ▶ **Ricorrente**: lo stato viene rivisitato quasi certamente.
- ▶ **Transiente**: c'è probabilità positiva di non tornarci più.

Nelle catene finite irriducibili, tutti gli stati sono ricorrenti positivi.

Punto di vista spettrale

$$\mu^{(0)} = \pi + \sum_{k \geq 2} c_k v_k,$$

con $v_k P = \lambda_k v_k$, $\pi P = \pi$. Dopo n passi,

$$\mu^{(0)} P^n = \pi + \sum_{k \geq 2} c_k \lambda_k^n v_k.$$

Se la catena è ergodica, gli autovalori diversi da 1 soddisfano $|\lambda_k| < 1$, quindi i modi transitori decadono e resta solo la distribuzione stazionaria π .


Ergodicità e transienti

Una catena **finita, irriducibile e aperiodica** è ergodica. Siccome i *modi transienti* decadono con il numero di passi, la catena “dimentica” la condizione iniziale.

Per i metodi MCMC:

Proprietà	Ruolo
Irriducibilità	esplora tutto lo spazio
Aperiodicità	evita cicli rigidi
Ergodicità	garantisce convergenza a π

Convergenza di una catena con tre condizioni iniziali diverse



Flussi di probabilità e stazionarietà

Distribuzione stazionaria e bilancio globale

Per una distribuzione stazionaria π vale

$$\pi_j = \sum_i \pi_i P_{ij}.$$

Interpretazione: - il flusso totale che entra in j in un passo è

$$\sum_i \pi_i P_{ij},$$

- il flusso totale che esce da j è

$$\pi_j \sum_k P_{jk} = \pi_j.$$

Quindi, in equilibrio, flusso entrante e uscente coincidono.

Bilancio dettagliato

Il **bilancio dettagliato** richiede che il flusso sia bilanciato stato per stato:


$$\pi_i P_{ij} = \pi_j P_{ji} \quad \text{per ogni } i, j.$$

Implica la stazionarietà, ma **non** è equivalente ad essa in generale.

Significato: in equilibrio il flusso $i \rightarrow j$ uguaglia il flusso $j \rightarrow i$.

Una catena che soddisfa il bilancio dettagliato rispetto a π si dice **reversibile** rispetto a π .

$\Rightarrow$ Metropolis e Metropolis-Hastings sono progettati esattamente per soddisfare questa condizione.



Flussi bilanciati tra coppie di stati in equilibrio

Perché usare MCMC?

Vogliamo calcolare

$$\langle A \rangle_{\pi} = \int A(x) \pi(x) dx$$

ma non sappiamo campionare direttamente da π .

Spesso π è nota solo nella forma

$$\pi(x) = \frac{1}{Z} \tilde{\pi}(x),$$

dove $\tilde{\pi}$ è calcolabile e Z non lo è.

Principio ergodico: se la catena è ergodica con stazionaria π ,

$$\frac{1}{N} \sum_{t=1}^N A(X_t) \rightarrow \langle A \rangle_{\pi} \quad (N \rightarrow \infty).$$

Esempi di π con Z intrattabile:

Contesto	$\tilde{\pi}(x)$	Z
Fisica stat.	$e^{-\beta E(x)}$	funz. di partizione
Bayes	$L(y \theta) p(\theta)$	evidenza marginale
Reti	$e^{-H(x)}$	normalizzazione

Due conseguenze pratiche

Burn-in (termalizzazione)

I primi passi risentono della condizione iniziale.


Si scarta la parte iniziale della traiettoria prima di stimare le osservabili.

Campioni correlati

A differenza del Monte Carlo diretto, i campioni successivi non sono indipendenti.

$$N_{\text{eff}} = \frac{N}{\tau} < N$$

dove τ è il tempo di autocorrelazione.



Traiettoria con burn-in (zona grigia) e campioni correlati

Algoritmo di Metropolis

Mossa = Proposta + Accettazione

Ingredienti:

1. una proposta simmetrica $q(x' | x) = q(x | x')$
2. una regola di accettazione

Regola di accettazione:

$$A(x \rightarrow x') = \min\left(1, \frac{\tilde{\pi}(x')}{\tilde{\pi}(x)}\right).$$

- ▶ se x' è più probabile: accetta sempre
- ▶ se x' è meno probabile: accetta con probabilità $\tilde{\pi}(x')/\tilde{\pi}(x)$

Se rifiutata: $X_{t+1} = x$ (si resta fermi).

Z si cancella nel rapporto $\Rightarrow$ non serve calcolarlo.

Metropolis: caso di Boltzmann

Se $\pi(x) \propto e^{-\beta E(x)}$, il rapporto diventa


$$\frac{\tilde{\pi}(x')}{\tilde{\pi}(x)} = e^{-\beta(E(x')-E(x))}.$$

La probabilità di accettazione è quindi

$$A(x \rightarrow x') = \min(1, e^{-\beta \Delta E}),$$

dove $\Delta E = E(x') - E(x)$.

- ▶ $\Delta E < 0$ (energia diminuisce): accetta sempre
- ▶ $\Delta E > 0$ (energia cresce): accetta con probabilità $e^{-\beta \Delta E}$



Probabilità di accettazione in funzione di ΔE per diversi β

Metropolis: bilancio dettagliato

Per $x \neq x'$, il kernel di transizione è $P(x \rightarrow x') = q(x' | x) A(x \rightarrow x')$.

Moltiplicando per $\pi(x)$ e usando la simmetria di q :

$$\pi(x) P(x \rightarrow x') = q(x' | x) \min(\pi(x), \pi(x')).$$

Questa espressione è **simmetrica** in $x \leftrightarrow x'$, quindi

$$\pi(x) P(x \rightarrow x') = \pi(x') P(x' \rightarrow x).$$

Il detailed balance è verificato $\Rightarrow \pi$ è stazionaria.

Metropolis: pseudocodice

```
def metropolis(x0, n_steps):  
    x = x0  
    samples = []  
    for _ in range(n_steps):  
        x_new = propose_symmetric(x)  
        r = pi_tilde(x_new) / pi_tilde(x)  
        alpha = min(1.0, r)  
        if uniform_0_1() < alpha:  
            x = x_new  
        samples.append(x)  
    return samples
```

Note:

- ▶ propose_symmetric:
qualunque proposta con
 $q(x' | x) = q(x | x')$
- ▶ pi_tilde: densità **non normalizzata**
- ▶ se rifiutato, il punto
corrente viene **ripetuto** nei
campioni

Algoritmo di Metropolis-Hastings

MH: Imporre il detailed balance

Vogliamo costruire $P(x \rightarrow x')$ in modo che π sia stazionaria.

Imponiamo

$$\pi(x) P(x \rightarrow x') = \pi(x') P(x' \rightarrow x).$$

Se scriviamo

$$P(x \rightarrow x') = q(x' | x) A(x \rightarrow x'),$$

allora otteniamo

$$\pi(x) q(x' | x) A(x \rightarrow x') = \pi(x') q(x | x') A(x' \rightarrow x).$$

MH: regola di accettazione

Una scelta che soddisfa il detailed balance è

$$A(x \rightarrow x') = \min \left(1, \frac{\pi(x') q(x | x')}{\pi(x) q(x' | x)} \right) .$$

Infatti allora

$$\pi(x) P(x \rightarrow x') = \min \left(\pi(x) q(x' | x), \pi(x') q(x | x') \right) ,$$

che è simmetrico nello scambio $x \leftrightarrow x'$. (n.b.: se q è simmetrica, usando l'identità $\min(a, b) = a \min(1, a/b)$ valida per $a, b > 0$ otteniamo la regola di Metropolis)

MH: proposta non simmetrica

Con proposta $q(x' | x)$ non necessariamente simmetrica, la regola di accettazione diventa

$$A(x \rightarrow x') = \min\left(1, \frac{\tilde{\pi}(x') q(x | x')}{\tilde{\pi}(x) q(x' | x)}\right).$$

Il **fattore di Hastings** $q(x | x')/q(x' | x)$ corregge l'asimmetria della proposta.

Metropolis come caso particolare:

se $q(x' | x) = q(x | x')$, il fattore si semplifica e si recupera la regola di Metropolis.

Esempio di proposta asimmetrica:

$$q(i+1 | i) = 0.7, \quad q(i-1 | i) = 0.3.$$

Senza correzione: drift artificiale verso destra.

Il fattore di Hastings **compensa** esattamente questo sbilanciamento.


Heat bath / Gibbs sampling

Aggiornamento condizionato

Se la configurazione è $x = (x_1, \dots, x_n)$, si aggiorna x_i **campionando esattamente** dalla distribuzione condizionata:

$$\pi(x_i \mid x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n).$$

La proposta **coincide** con la condizionata target
 $\Rightarrow$ accettazione sempre uguale a 1, nessun rifiuto.
Gibbs sampling: aggiornamento ciclico di tutte le componenti.



Aggiornamento di una componente alla volta lungo le condizionate

Due esempi

Modello di Ising

Ogni spin $s_i \in \{-1, +1\}$.

Fissati i vicini, la condizionata di s_i dipende solo dal campo locale.

Si campiona direttamente il nuovo s_i : nessun rifiuto.

Modello bayesiano gerarchico

$$\pi(\mu, \sigma \mid y) \propto L(y \mid \mu, \sigma) p(\mu) p(\sigma).$$

Se $\pi(\mu \mid \sigma, y)$ è gaussiana, si campiona direttamente.

Si alterna: $\mu \mid \sigma, y$ poi $\sigma \mid \mu, y$.

Riepilogo

	Metropolis	MH	Gibbs
Proposta	simmetrica	qualsunque	condizionata
Accettazione	$\min(1, \tilde{\pi}' / \tilde{\pi})$	rapporto MH	sempre 1
Richiede	$\tilde{\pi}$	$\tilde{\pi}, q$	condizionate esplicite
Rifiuti	possibili	possibili	no
Generalità	alta	massima	dipende dal modello

Quando scegliere cosa:

- ▶ **Metropolis:** semplice, proposta naturale (es. random walk)
- ▶ **MH:** proposta informata, asimmetrica, su spazi complessi
- ▶ **Gibbs:** condizionate semplici, modelli gerarchici

Efficienza


Tasso di accettazione

Nel random walk Metropolis, l'ampiezza della proposta determina il tasso di accettazione:

- ▶ passi **troppo piccoli** $\Rightarrow$ quasi tutto accettato, ma esplorazione lenta
- ▶ passi **troppo grandi** $\Rightarrow$ quasi tutto rifiutato, catena ferma

L'efficienza dipende dal compromesso tra ampiezza e tasso di accettazione.

Regola pratica: in spazi continui, un tasso di accettazione intorno al 20-40% è spesso un buon punto di partenza.



Traiettorie con tasso di accettazione troppo alto, ottimale, troppo basso

Autocorrelazione e indipendenza

Per un'osservabile $A_t = A(X_t)$, la funzione di autocorrelazione è


$$C(\tau) = \langle A_t A_{t+\tau} \rangle - \langle A \rangle^2.$$

Il tempo di autocorrelazione integrato

τ_{int} misura quanti passi equivalgono a un campione indipendente.

Il numero effettivo di campioni:

$$N_{\text{eff}} = \frac{N}{\tau_{\text{int}}} \ll N.$$




Funzione di autocorrelazione per catene con mixing rapido e lento

Metastabilità e multimodalità

Se π ha più modi separati da **barriere elevate**, la catena può restare intrappolata a lungo in una sola regione. I tempi di mixing diventano enormi: la stima numerica risulta distorta pur essendo l'algoritmo formalmente corretto.

Soluzioni parziali:

- ▶ Simulated Annealing
- ▶ Parallel Tempering
- ▶ Hamiltonian Monte Carlo




Catena intrappolata in un modo: l'altro resta inesplorato

Diagnostica empirica

Strumenti pratici:

- ▶ andamento temporale delle osservabili (stazionarietà visiva)
- ▶ stabilità delle medie cumulative
- ▶ confronto tra catene con condizioni iniziali diverse
- ▶ autocorrelazioni empiriche
- ▶ frequenza di accettazione

Questi strumenti **non sostituiscono** la teoria, ma sono indispensabili per valutare una simulazione concreta.



Diagnostica: medie cumulative, autocorrelazione, confronto tra catene

Estensioni

Metropolis adattivo

La proposta viene aggiornata durante la simulazione usando l'informazione empirica raccolta dalla catena.

Hamiltonian Monte Carlo

Usa variabili ausiliarie di momento e una dinamica quasi deterministica per proporre mosse lunghe con alta accettazione.

Simulated annealing

Introduce una temperatura decrescente nel tempo per trasformare il campionamento in una procedura di ottimizzazione globale.

Dove ricompaiono queste idee

Contesto	Metodo dominante
Modelli di spin	Metropolis, heat bath
Inferenza bayesiana	MH, Gibbs, HMC
Boltzmann machine	Gibbs, heat bath
Ottimizzazione combinatoria	simulated annealing

Take-home message

- ▶ una catena di Markov ergodica converge a un'unica π , qualunque sia la condizione iniziale
- ▶ il detailed balance è il principio costruttivo per progettare dinamiche corrette
- ▶ Metropolis: proposta simmetrica, Z si cancella nel rapporto
- ▶ Metropolis-Hastings: generalizza a proposte asimmetriche con il fattore di Hastings
- ▶ heat bath / Gibbs: nessun rifiuto, richiede condizionate esplicite
- ▶ correttezza teorica $\neq$ efficienza pratica: burn-in, autocorrelazione, metastabilità contano

Prossima lezione:

- ▶ equazioni differenziali stocastiche (SDE)
- ▶ rumore diffusivo e rumore impulsivo
- ▶ la struttura MCMC tornerà come strumento di simulazione delle SDE