

Lezione 09 – Stima dei parametri e log-likelihood

Metodi computazionali per modelli stocastici

Antonio Scala

Obiettivi

Obiettivi della lezione

In questa lezione introduciamo il problema della **stima dei parametri** nei modelli stocastici.

Alla fine della lezione dovremmo saper:

- ▶ costruire likelihood e log-likelihood;
- ▶ calcolare stimatori MLE in esempi elementari;
- ▶ interpretare score, Hessiano e informazione di Fisher;
- ▶ stimare parametri in catene di Markov, processi di salto e SDE;
- ▶ distinguere stima, incertezza, diagnostica e goodness-of-fit;
- ▶ riconoscere casi in cui la likelihood è intrattabile.

Dal problema diretto al problema inverso

Problema diretto:

$$\theta \longrightarrow \text{modello probabilistico} \longrightarrow \text{dati}$$

Problema inverso:

$$\text{dati} \longrightarrow \text{stima di } \theta$$

Domanda guida:

Quali valori di θ rendono i dati osservati più plausibili sotto il modello?

Parametro, dati, stimatore

Supponiamo di osservare

$$x_1, x_2, \dots, x_n.$$

Il modello contiene un parametro, o vettore di parametri,

$$\theta \in \Theta.$$

Uno **stimatore** è una funzione dei dati:

$$\hat{\theta} = \hat{\theta}(x_1, \dots, x_n).$$

Poiché i dati sono casuali, anche $\hat{\theta}$ è una variabile aleatoria.

Criteri desiderabili

Uno stimatore dovrebbe essere:

- ▶ **consistente**: tende al parametro vero per $n \rightarrow \infty$;
- ▶ **non distorto**, almeno asintoticamente;
- ▶ **efficiente**: usa bene l'informazione disponibile;
- ▶ **robusto**: non cambia drasticamente per piccole perturbazioni;
- ▶ **numericamente stabile**: è calcolabile in modo affidabile.

La massima verosimiglianza fornisce un criterio generale per costruire stimatori.

Likelihood e log-likelihood

Likelihood

Per un singolo dato:

$$p(x \mid \theta).$$

Per un campione indipendente:

$$p(x_1, \dots, x_n \mid \theta) = \prod_{i=1}^n p(x_i \mid \theta).$$

Vista come funzione di θ , a dati fissati, questa quantità è la **likelihood**:

$$L(\theta) = \prod_{i=1}^n p(x_i \mid \theta).$$

Distribuzione o likelihood?

Attenzione alla distinzione:

- ▶ $p(x | \theta)$ è una distribuzione in x , a parametro fissato;
- ▶ $L(\theta)$ è una funzione di θ , a dati fissati.

In generale $L(\theta)$ **non** è una distribuzione di probabilità su θ .

Non deve integrare a uno rispetto a θ .

Perché il logaritmo?

La likelihood di dati indipendenti è un prodotto:

$$L(\theta) = \prod_{i=1}^n p(x_i \mid \theta).$$

Il logaritmo trasforma prodotti in somme:

$$\ell(\theta) = \log L(\theta) = \sum_{i=1}^n \log p(x_i \mid \theta).$$

Vantaggi:

- ▶ maggiore stabilità numerica;
- ▶ derivate più semplici;
- ▶ contributi additivi dei singoli dati.

Negative log-likelihood

Massimizzare ℓ equivale a massimizzare L , perché $\log$ è monotono crescente.

Spesso si minimizza invece la **negative log-likelihood**:

$$\mathcal{J}(\theta) = -\ell(\theta).$$

La stima di massima verosimiglianza, MLE, è

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta \in \Theta} \ell(\theta) = \arg \min_{\theta \in \Theta} \mathcal{J}(\theta).$$

Massima verosimiglianza

Condizione del primo ordine

Se θ è scalare e il massimo è interno a Θ :

$$\frac{d\ell}{d\theta}(\hat{\theta}) = 0.$$

La derivata della log-likelihood è lo **score**:

$$S(\theta) = \frac{d\ell}{d\theta}.$$

Quindi:

$$S(\hat{\theta}) = 0.$$

Caso vettoriale

Se

$$\theta = (\theta_1, \dots, \theta_d),$$

lo score è il gradiente:

$$S(\theta) = \nabla_{\theta} \ell(\theta).$$

Per un massimo interno:

$$\nabla_{\theta} \ell(\hat{\theta}) = 0.$$

Se il massimo cade sul bordo di Θ , la condizione corretta è che non esista alcuna direzione ammissibile lungo cui ℓ aumenti al primo ordine.

Condizione del secondo ordine

Caso scalare:

$$\frac{d^2\ell}{d\theta^2}(\hat{\theta}) < 0.$$

Caso vettoriale:

$$H(\theta) = \nabla_{\theta}^2 \ell(\theta)$$

deve essere definito negativo al massimo interno.

La curvatura non serve solo a verificare il massimo: contiene informazione sull'incertezza della stima.

Esempi fondamentali

Bernoulli

Dati:

$$x_i \in \{0, 1\}, \quad P(X_i = 1) = p.$$

Likelihood:

$$L(p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i}.$$

Se

$$k = \sum_i x_i,$$

allora

$$\ell(p) = k \log p + (n - k) \log(1 - p).$$

MLE:

$$\hat{p} = \frac{k}{n}.$$

Poisson

Dati:

$$X_i \sim \text{Poisson}(\lambda), \quad P(X_i = x_i \mid \lambda) = \frac{\lambda^{x_i} e^{-\lambda}}{x_i!}.$$

Log-likelihood:

$$\ell(\lambda) = \left(\sum_i x_i \right) \log \lambda - n\lambda + \text{costante}.$$

MLE:

$$\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Esponenziale

Tempi di attesa indipendenti:

$$p(t \mid \lambda) = \lambda e^{-\lambda t}, \quad t \geq 0.$$

Likelihood:

$$L(\lambda) = \lambda^n e^{-\lambda \sum_i t_i}.$$

Log-likelihood:

$$\ell(\lambda) = n \log \lambda - \lambda \sum_i t_i.$$

MLE:

$$\hat{\lambda} = \frac{n}{\sum_i t_i} = \frac{1}{\bar{t}}.$$

Gaussiana con varianza nota

Dati con σ^2 nota:

$$X_i \sim \mathcal{N}(\mu, \sigma^2),$$

Log-likelihood:

$$\ell(\mu) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_i (x_i - \mu)^2.$$

MLE:

$$\hat{\mu} = \bar{x}.$$

Gaussiana con media e varianza ignote

Se μ e σ^2 sono ignote:

$$\hat{\mu} = \bar{x}.$$

La MLE della varianza è

$$\hat{\sigma}_{\text{MLE}}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Attenzione:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

è invece lo stimatore non distorto della varianza.

Score, Hessiano, Fisher

Score e Hessiano

Score:

$$S(\theta) = \nabla_{\theta} \ell(\theta).$$

Hessiano:

$$H(\theta) = \nabla_{\theta}^2 \ell(\theta).$$

Informazione osservata:

$$\mathcal{I}_{\text{obs}}(\hat{\theta}) = -H(\hat{\theta}).$$

Il segno meno rende positiva la curvatura al massimo.

Informazione di Fisher elementare

Per una singola osservazione X :

$$s(x; \theta) = \nabla_{\theta} \log p(x \mid \theta).$$

L'informazione di Fisher per singola osservazione è

$$I_1(\theta) = \mathbb{E}_{\theta}[s(X; \theta)s(X; \theta)^T].$$

Qui $s s^T$ è un prodotto esterno: se $\theta \in \mathbb{R}^d$, allora I_1 è una matrice $d \times d$.

Interpretazione geometrica

Per una direzione unitaria u :

$$u^T I_1(\theta) u = \mathbb{E}_\theta[(u^T s(X; \theta))^2].$$

Quindi $u^T I_1 u$ misura il valore medio del quadrato della componente dello score lungo u .

- ▶ grande: la distribuzione cambia molto lungo u ;
- ▶ piccolo: il parametro è poco identificabile lungo u .

Identità con l'Hessiano medio

Sotto condizioni regolari:

$$I_1(\theta) = -\mathbb{E}_\theta[\nabla_\theta^2 \log p(X | \theta)].$$

Idea della dimostrazione:

$$\mathbb{E}_\theta[s_i] = \int \frac{\partial p(x | \theta)}{\partial \theta_i} dx = \frac{\partial}{\partial \theta_i} \int p(x | \theta) dx = 0.$$

Derivando ancora:

$$\mathbb{E}_\theta[s_i s_j] = -\mathbb{E}_\theta \left[\frac{\partial^2}{\partial \theta_j \partial \theta_i} \log p(X | \theta) \right].$$

Informazione del campione

Per un campione indipendente:

$$\ell_n(\theta) = \sum_{k=1}^n \log p(X_k \mid \theta).$$

Score totale:

$$S_n(\theta) = \nabla_{\theta} \ell_n(\theta) = \sum_{k=1}^n s(X_k; \theta).$$

Informazione totale:

$$I_n(\theta) = \mathbb{E}_{\theta}[S_n S_n^T].$$

(nel caso i.i.d.: $I_n(\theta) \equiv n I_1(\theta)$.)

Incertezza della stima

Approssimazione quadratica

Vicino al massimo:

$$\ell_n(\theta) \approx \ell_n(\hat{\theta}) - \frac{1}{2}(\theta - \hat{\theta})^T \mathcal{I}_{\text{obs}}(\hat{\theta})(\theta - \hat{\theta}).$$

Se la curvatura è grande, il massimo è ben localizzato.

Se la curvatura è piccola, la log-likelihood è piatta e la stima è incerta.

Varianza asintotica

Per campioni grandi:

$$\hat{\theta}_{\text{MLE}} \approx \mathcal{N} \left(\theta_0, I_n(\theta_0)^{-1} \right).$$

Nel caso i.i.d.:

$$I_n(\theta_0) = n I_1(\theta_0),$$

quindi

$$\hat{\theta}_{\text{MLE}} \approx \mathcal{N} \left(\theta_0, \frac{1}{n} I_1(\theta_0)^{-1} \right).$$

Covarianza dello stimatore

In pratica θ_0 non è noto.

Si usa la curvatura osservata nel punto stimato:

$$\mathcal{I}_{\text{obs}}(\hat{\theta}) = -\nabla_{\theta}^2 \ell_n(\hat{\theta}).$$

La covarianza stimata dello stimatore è

$$\widehat{\text{Cov}}(\hat{\theta}) \approx \mathcal{I}_{\text{obs}}(\hat{\theta})^{-1}.$$

Non è la covarianza dei dati: è l'incertezza sui parametri stimati.

Interpretazione informazionale

Distribuzione empirica e modello

Per semplicità consideriamo esiti discreti.

I dati definiscono una distribuzione empirica

$$p_{\text{data}}(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{x_i=x}.$$

Il modello assegna una distribuzione teorica

$$q_{\theta}(x).$$

Allora

$$\frac{1}{n} \ell(\theta) = \sum_x p_{\text{data}}(x) \log q_{\theta}(x).$$

Cross-entropia

La negative log-likelihood media è

$$-\frac{1}{n}\ell(\theta) = -\sum_x p_{\text{data}}(x) \log q_{\theta}(x).$$

Questa è la cross-entropia:

$$H(p_{\text{data}}, q_{\theta}) = -\sum_x p_{\text{data}}(x) \log q_{\theta}(x).$$

Interpretazione: sorpresa media dei dati se usiamo il modello q_{θ} .

Divergenza KL

La divergenza di Kullback–Leibler nasce come eccesso di sorpresa:

$$D_{\text{KL}}(p\|q) = H(p, q) - H(p).$$

Equivalentemente:

$$D_{\text{KL}}(p\|q) = \sum_x p(x) \log \frac{p(x)}{q(x)}.$$

È una divergenza, in generale non è una distanza:

$$D_{\text{KL}}(p\|q) \neq D_{\text{KL}}(q\|p)$$

MLE come minimizzazione della KL

Nel nostro caso:

$$p = p_{\text{data}}, \quad q = q_{\theta}.$$

Allora:

$$D_{\text{KL}}(p_{\text{data}} \| q_{\theta}) = \sum_x p_{\text{data}}(x) \log p_{\text{data}}(x) - \sum_x p_{\text{data}}(x) \log q_{\theta}(x).$$

Il primo termine non dipende da θ .

Quindi:

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \ell(\theta) = \arg \min_{\theta} D_{\text{KL}}(p_{\text{data}} \| q_{\theta}).$$

Dati dipendenti e traiettorie

Likelihood di traiettoria

Per una traiettoria markoviana a tempo discreto:

$$x_0, x_1, \dots, x_T,$$

la probabilità si fattorizza come

$$P(x_0, \dots, x_T \mid \theta) = P(x_0 \mid \theta) \prod_{t=0}^{T-1} P(x_{t+1} \mid x_t, \theta).$$

La log-likelihood è

$$\ell(\theta) = \log P(x_0 \mid \theta) + \sum_{t=0}^{T-1} \log P(x_{t+1} \mid x_t, \theta).$$

Catena di Markov discreta

Matrice di transizione:

$$P_{ij}(\theta) = P(X_{t+1} = j \mid X_t = i, \theta).$$

Conteggi di transizione:

$$N_{ij} = \#\{t : x_t = i, x_{t+1} = j\}.$$

Log-likelihood:

$$\ell(\theta) = \sum_{i,j} N_{ij} \log P_{ij}(\theta).$$

Se ogni riga è libera:

$$\hat{P}_{ij} = \frac{N_{ij}}{\sum_k N_{ik}}.$$

Dipendenza e informazione effettiva

Quando i dati sono dipendenti, N osservazioni non equivalgono a N dati indipendenti.

L'autocorrelazione riduce l'informazione effettiva.

Conseguenze:

- ▶ errori standard troppo ottimistici;
- ▶ sovrastima dell'informazione nei dati;
- ▶ diagnostica necessaria su autocorrelazione e mixing.

Processi di salto

Tassi di transizione

Consideriamo un processo markoviano a tempo continuo con stati discreti.

Tassi:

$$w_{i \rightarrow j}(\theta).$$

Tasso totale di uscita da i :

$$r_i(\theta) = \sum_{j \neq i} w_{i \rightarrow j}(\theta).$$

Tempo di permanenza in i :

$$p(\tau \mid i) = r_i e^{-r_i \tau}.$$

Likelihood elementare

Probabilità che il salto sia verso j :

$$\frac{w_{i \rightarrow j}}{r_i}.$$

Densità congiunta: permanenza τ in i e salto $i \rightarrow j$:

$$r_i e^{-r_i \tau} \frac{w_{i \rightarrow j}}{r_i} = w_{i \rightarrow j} e^{-r_i \tau}.$$

Likelihood elementare:

$$L_{i \rightarrow j}(\theta; \tau) = w_{i \rightarrow j}(\theta) e^{-r_i(\theta) \tau}.$$

Traiettoria completa

Se la traiettoria è composta da tratti

$$(i_0, \tau_0, i_1), \dots, (i_{M-1}, \tau_{M-1}, i_M),$$

allora

$$L(\theta) = \prod_{m=0}^{M-1} w_{i_m \rightarrow i_{m+1}}(\theta) e^{-r_{i_m}(\theta) \tau_m}.$$

Raggruppando:

$$L(\theta) = \prod_{i \neq j} w_{i \rightarrow j}(\theta)^{N_{ij}} \exp \left[- \sum_i T_i r_i(\theta) \right].$$

Log-likelihood e stima dei tassi

Log-likelihood:

$$\ell(\theta) = \sum_{i \neq j} N_{ij} \log w_{i \rightarrow j}(\theta) - \sum_i T_i r_i(\theta).$$

Se i tassi sono liberi:

$$r_i = \sum_{j \neq i} w_{i \rightarrow j}.$$

Allora

$$\frac{\partial \ell}{\partial w_{i \rightarrow j}} = \frac{N_{ij}}{w_{i \rightarrow j}} - T_i.$$

MLE:

$$\hat{w}_{i \rightarrow j} = \frac{N_{ij}}{T_i}.$$

SDE osservate a tempi discreti

Euler–Maruyama come likelihood approssimata

SDE:

$$dX_t = a(X_t, \theta)dt + b(X_t, \theta)dW_t.$$

Quindi:

$$X_{k+1} \mid X_k = x_k \approx \mathcal{N}\left(x_k + a(x_k, \theta)\Delta t, b(x_k, \theta)^2\Delta t\right)$$

Per piccoli Δt :

$$X_{k+1} \approx X_k + a(X_k, \theta)\Delta t + b(X_k, \theta)\sqrt{\Delta t}\xi_k,$$

con

$$\xi_k \sim \mathcal{N}(0, 1).$$

Log-likelihood approssimata

La log-likelihood approssimata è

$$\ell(\theta) \approx -\frac{1}{2} \sum_{k=0}^{N-1} \left[\log(2\pi b_k^2 \Delta t) + \frac{(x_{k+1} - x_k - a_k \Delta t)^2}{b_k^2 \Delta t} \right],$$

dove

$$a_k = a(x_k, \theta), \quad b_k = b(x_k, \theta).$$

Drift come regressione sugli incrementi

Se $b(x, \theta) = \sigma$ è nota e costante:

$$\Delta x_k = a(x_k, \theta) \Delta t + \sigma \sqrt{\Delta t} \xi_k.$$

Gli incrementi osservati Δx_k sono la variabile risposta.

La previsione del modello è

$$a(x_k, \theta) \Delta t.$$

La MLE minimizza

$$\sum_k [\Delta x_k - a(x_k, \theta) \Delta t]^2.$$

Ornstein–Uhlenbeck

SDE:

$$dX_t = -\gamma X_t dt + \sigma dW_t.$$

Euler–Maruyama:

$$\Delta x_k = -\gamma x_k \Delta t + \sigma \sqrt{\Delta t} \xi_k.$$

Se σ è nota:

$$Q(\gamma) = \sum_k (\Delta x_k + \gamma x_k \Delta t)^2.$$

MLE approssimata:

$$\hat{\gamma} = -\frac{\sum_k x_k \Delta x_k}{\Delta t \sum_k x_k^2}.$$

Nota sul propagatore esatto

Per Ornstein–Uhlenbeck il propagatore esatto è noto:

$$X_{k+1} \mid X_k = x_k \sim \mathcal{N} \left(x_k e^{-\gamma \Delta t}, \frac{\sigma^2}{2\gamma} (1 - e^{-2\gamma \Delta t}) \right).$$

Quindi si può costruire una likelihood esatta della traiettoria discretamente osservata.

Per Δt piccolo si recupera Euler–Maruyama; per Δt non infinitesimo il propagatore esatto è preferibile.

Diagnostica e confronto modello-dati

Problemi tipici

La stima non basta: serve diagnostica.

Patologie frequenti:

- ▶ parametri non identificabili;
- ▶ massimi locali;
- ▶ vincoli ignorati;
- ▶ underflow nella likelihood;
- ▶ dati correlati trattati come indipendenti;
- ▶ overfitting.

Identificabilità

Un parametro è identificabile se valori diversi producono distribuzioni osservabili diverse.

Se

$$p(x \mid \theta_1) = p(x \mid \theta_2),$$

allora nessun metodo può distinguere θ_1 da θ_2 usando quei dati.

Segnali:

- ▶ log-likelihood piatta;
- ▶ Hessiano quasi singolare;
- ▶ forti correlazioni tra parametri;
- ▶ stime instabili.

Goodness-of-fit

Dopo aver stimato $\hat{\theta}$:

Il modello con parametro $\hat{\theta}$ riproduce le proprietà statistiche rilevanti dei dati?

Strumenti:

- ▶ QQ-plot;
- ▶ test KS, con cautela se i parametri sono stimati dagli stessi dati;
- ▶ confronto tra dati osservati e simulati;
- ▶ residui trasformati per processi puntuali;
- ▶ AIC e BIC per confronto tra modelli.

Residui trasformati

Per eventi ai tempi t_k con intensità condizionata stimata $\lambda_{\hat{\theta}}^*(t)$:

$$\tau_k = \int_0^{t_k} \lambda_{\hat{\theta}}^*(s) ds.$$

Questa variabile è adimensionale: è il numero atteso cumulativo di eventi fino a t_k .

Se il modello è corretto:

$$z_k = \tau_k - \tau_{k-1} \sim \text{Exp}(1).$$

Quindi si può usare un QQ-plot contro una esponenziale standard.

AIC e BIC

Un modello con più parametri tende ad avere likelihood più alta.

Criteri penalizzati:

$$\text{AIC} = 2k - 2\ell(\hat{\theta}),$$

$$\text{BIC} = k \log n - 2\ell(\hat{\theta}).$$

Valori più bassi indicano un compromesso migliore tra adattamento e complessità.

Likelihood intrattabile

Quando la likelihood non si calcola

La likelihood può essere intrattabile quando:

- ▶ ci sono variabili latenti;
- ▶ si osservano solo statistiche aggregate;
- ▶ lo spazio degli stati è enorme;
- ▶ il modello è agent-based;
- ▶ la dinamica è simulabile ma la densità dei dati non è nota.

Idea generale:

se non posso calcolare la probabilità dei dati, posso simulare il modello e confrontare dati simulati e osservati.

Metodo dei momenti simulati

Sia m_{obs} un vettore di statistiche osservate.

Per ogni θ , simuliamo il modello e calcoliamo

$$m_{\text{sim}}(\theta).$$

Scegliamo θ minimizzando

$$\hat{\theta}_{\text{SMM}} = \arg \min_{\theta} [m_{\text{obs}} - m_{\text{sim}}(\theta)]^T W [m_{\text{obs}} - m_{\text{sim}}(\theta)].$$

Il punto cruciale è la scelta delle statistiche.

Approximate Bayesian Computation

ABC è un approccio bayesiano per modelli simulabili con likelihood intrattabile.

Schema rejection:

1. estrai $\theta \sim p(\theta)$;
2. simula $y_{\text{sim}} \sim p(\cdot \mid \theta)$;
3. calcola $s(y_{\text{sim}})$ e $s(y_{\text{obs}})$;
4. accetta θ se

$$d(s(y_{\text{sim}}), s(y_{\text{obs}})) \leq \varepsilon.$$

I parametri accettati approssimano la posteriore.

Il ruolo di ε

La soglia ε controlla la tolleranza.

- ▶ ε piccolo: approssimazione più accurata, accettazione rara;
- ▶ ε grande: più accettazioni, posteriore meno informativa.

ABC conclude il percorso:

1. likelihood esplicita – MLE;
2. likelihood approssimata – Euler–Maruyama;
3. likelihood intrattabile – simulazione, SMM, ABC.

Sintesi

Messaggi finali

La log-likelihood è lo strumento operativo centrale perché:

- ▶ trasforma prodotti in somme;
- ▶ evita instabilità numeriche;
- ▶ permette ottimizzazione e derivate;
- ▶ collega inferenza, entropia e KL.

La MLE produce stimatori naturali:

- ▶ frequenze empiriche;
- ▶ medie campionarie;
- ▶ tassi evento/tempo;
- ▶ parametri di drift e diffusione.

Dai dati indipendenti ai modelli dinamici

Per dati indipendenti:

$$\ell(\theta) = \sum_i \log p(x_i \mid \theta).$$

Per traiettorie dinamiche:

$$\ell(\theta) = \log P(x_0 \mid \theta) + \sum_t \log P(x_{t+1} \mid x_t, \theta).$$

Nei modelli continui:

- ▶ processi di salto: likelihood da tempi di permanenza e salti;
- ▶ SDE: likelihood approssimata o propagatore esatto.

Ultimo messaggio

La stima parametrica non è solo calcolo di una formula.

Richiede:

- ▶ costruzione corretta della likelihood;
- ▶ gestione dei vincoli;
- ▶ stima dell'incertezza;
- ▶ diagnostica modello-dati;
- ▶ attenzione a dipendenza, autocorrelazione e simulazione.

Nei modelli complessi, l'inferenza non è separata dalla simulazione: spesso passa proprio attraverso di essa.

Esercizi

Esercizi proposti

1. Bernoulli: derivare $\hat{p} = k/n$.
2. Poisson: stimare λ da conteggi osservati.
3. Esponenziale: stimare $\lambda = 1/\bar{t}$.
4. Catena di Markov: stimare $\hat{P}_{ij}$ dai conteggi.
5. Processo di salto: stimare $\hat{w}_{i \rightarrow j} = N_{ij}/T_i$.
6. SDE lineare: derivare la MLE approssimata di γ .
7. Diagnostica: interpretare un Hessiano quasi singolare.
8. Goodness-of-fit: costruire un QQ-plot.
9. Momenti simulati: scegliere statistiche informative.
10. ABC: discutere il ruolo di ε .