

S11 – Paesaggi di energia e modelli generativi

Metodi computazionali per modelli stocastici

Antonio Scala

Apertura

Obiettivo della lezione

Una funzione di costo, energia o loss può essere usata non solo per scegliere una configurazione, ma anche per definire una distribuzione di probabilità.

$$E(x) \longrightarrow p(x) = \frac{e^{-\beta E(x)}}{Z}$$

Idea centrale

- ▶ stati a bassa energia $\rightarrow$ più probabili;
- ▶ stati ad alta energia $\rightarrow$ meno probabili;
- ▶ generare significa campionare dalla distribuzione definita dall'energia.

Il filo conduttore

costo/loss $\longrightarrow$ energia $\longrightarrow$ distribuzione $\longrightarrow$ modello generativo

Nella lezione useremo questo filo per collegare:

- ▶ energy-based models;
- ▶ reti di Hopfield;
- ▶ Boltzmann Machines;
- ▶ Gibbs sampling;
- ▶ contrastive divergence;
- ▶ Hamiltonian Monte Carlo.

Tre problemi diversi

Una stessa energia può essere letta in tre modi.

Lettura	Domanda	Oggetto
Ottimizzazione	qual è la configurazione migliore?	$\arg \min_x E(x)$
Campionamento	quali configurazioni sono tipiche?	$p(x) \propto e^{-E(x)}$
Generazione	come produrre nuovi esempi plausibili?	$p_\theta(x)$ appresa dai dati

Questa lezione si concentra soprattutto sulle ultime due letture.

1. Da costo a probabilità

Una funzione energia

Sia $\mathcal{X}$ uno spazio di configurazioni.

Una configurazione $x \in \mathcal{X}$ può essere:

- ▶ un vettore continuo;
- ▶ una configurazione binaria;
- ▶ una sequenza;
- ▶ una rete;
- ▶ un insieme di parametri;
- ▶ uno stato collettivo.

Introduciamo una funzione

$$E : \mathcal{X} \rightarrow \mathbb{R}.$$

Un valore basso di $E(x)$ indica maggiore compatibilità con modello, dati o vincoli.

Pesi non normalizzati

A ogni configurazione associamo un peso positivo:

$$\tilde{p}(x) = e^{-\beta E(x)}.$$

La tilde ricorda che non è ancora una probabilità normalizzata.

Proprietà

$$\tilde{p}(x) > 0.$$

Se $E(x) < E(y)$, allora

$$\tilde{p}(x) > \tilde{p}(y).$$

Diminuire l'energia aumenta la plausibilità relativa.

Rapporti di probabilità

Il rapporto tra due pesi è

$$\frac{\tilde{p}(x)}{\tilde{p}(y)} = \exp[-\beta(E(x) - E(y))].$$

Quindi contano le **differenze di energia**, non il valore assoluto.

Se aggiungiamo una costante c a tutte le energie,

$$E'(x) = E(x) + c,$$

i rapporti non cambiano.

L'energia definisce una scala relativa di plausibilità.

Normalizzazione

Per ottenere una probabilità dividiamo per il peso totale.

Caso discreto: $Z = \sum_{x \in \mathcal{X}} e^{-\beta E(x)}$.

Caso continuo: $Z = \int_{\mathcal{X}} e^{-\beta E(x)} dx$.

Quindi

$$p(x) = \frac{e^{-\beta E(x)}}{Z}.$$

Z è la **funzione di partizione**.

Il ruolo di β

Il parametro β controlla quanto la distribuzione è sensibile alle differenze di energia.

- ▶ $\beta = 0$: tutti i pesi sono uguali;
- ▶ β piccolo: distribuzione diffusa;
- ▶ β grande: distribuzione concentrata sugli stati a bassa energia.

Spesso si introduce una temperatura T :

$$\beta = \frac{1}{T}.$$

Temperatura alta $\rightarrow$ distribuzione più diffusa.

Temperatura bassa $\rightarrow$ distribuzione più selettiva.

2. Boltzmann e funzione di partizione

Distribuzione di Boltzmann

La forma

$$p(x) = \frac{e^{-\beta E(x)}}{Z}$$

è la distribuzione di Boltzmann–Gibbs.

In questa lezione la usiamo in senso generale:

una funzione energia definisce una distribuzione su configurazioni.

La formula separa due oggetti:

- ▶ $E(x)$: quantità locale, valutabile su una configurazione;
- ▶ Z : quantità globale, dipendente da tutto lo spazio.

Perché Z è globale

L'energia è locale rispetto allo stato:

$E(x)$ dipende dalla configurazione x .

La funzione di partizione è globale:

$$Z = \sum_x e^{-\beta E(x)} \quad \text{o} \quad Z = \int e^{-\beta E(x)} dx.$$

Deve sommare o integrare il peso di tutte le configurazioni.

Nei problemi realistici questa operazione può essere impossibile.

Probabilità non normalizzate

Molti algoritmi usano solo rapporti:

$$\frac{p(x)}{p(y)} = \frac{e^{-\beta E(x)} / Z}{e^{-\beta E(y)} / Z} = e^{-\beta(E(x) - E(y))}.$$

La normalizzazione Z si cancella.

Questo permette di usare la densità non normalizzata

$$\tilde{p}(x) = e^{-\beta E(x)}.$$

Ma Z torna centrale quando vogliamo likelihood, probabilità assolute o apprendimento dei parametri.

Log-probabilità

Prendendo il logaritmo:

$$\log p(x) = -\beta E(x) - \log Z.$$

Due contributi:

- ▶ $-\beta E(x)$ dipende dalla configurazione osservata;
- ▶ $-\log Z$ dipende dall'intero modello.

Un modello non può rendere tutto molto probabile.

Se abbassa molte energie, aumenta anche Z .

La normalizzazione impone una competizione globale tra stati.

Parametri e normalizzazione

Negli energy-based models:

$$p_{\theta}(x) = \frac{e^{-E_{\theta}(x)}}{Z_{\theta}}.$$

Con $Z_{\theta} = \sum_x e^{-E_{\theta}(x)}$ o $Z_{\theta} = \int e^{-E_{\theta}(x)} dx$.

Cambiare θ modifica:

- ▶ l'energia dei dati;
- ▶ l'energia delle configurazioni non osservate;
- ▶ la normalizzazione Z_{θ} .

L'apprendimento deve quindi agire in modo relativo, non assoluto.

3. Energy-based models

Definizione

Un **energy-based model** definisce una distribuzione tramite una funzione energia parametrica:

$$p_{\theta}(x) = \frac{e^{-E_{\theta}(x)}}{Z_{\theta}}.$$

La forma è semplice ma generale. Possiamo rappresentare distribuzioni su:

- ▶ variabili continue;
- ▶ stati binari;
- ▶ immagini;
- ▶ reti;
- ▶ sequenze;
- ▶ variabili latenti;
- ▶ configurazioni collettive.

Perché usare un'energia

Spesso è difficile scrivere direttamente una distribuzione normalizzata.

È più naturale costruire una funzione che misuri incompatibilità:

- ▶ immagine poco realistica;
- ▶ rete non coerente con certe proprietà;
- ▶ configurazione biologica instabile;
- ▶ stato sociale incompatibile con vincoli di interazione;
- ▶ parametro che spiega male i dati.

L'energia diventa una misura di implausibilità.

Modello implicito

Un modello esplicito fornisce direttamente $p_{\theta}(x)$ normalizzata.

Un EBM fornisce prima un peso:

$$\tilde{p}_{\theta}(x) = e^{-E_{\theta}(x)}.$$

Poi serve normalizzare:

$$p_{\theta}(x) = \frac{\tilde{p}_{\theta}(x)}{Z_{\theta}}.$$

Il modello è quindi implicito:

- ▶ possiamo valutare pesi relativi;
- ▶ la probabilità assoluta richiede Z_{θ} ;
- ▶ campionamento e apprendimento diventano centrali.

Generare campioni

Generare non significa trovare il minimo di $E_\theta(x)$.

Significa produrre configurazioni con frequenze coerenti con

$$p_\theta(x) = \frac{e^{-E_\theta(x)}}{Z_\theta}.$$

Un modello generativo deve produrre varietà, non solo una configurazione ottima.

Se non sappiamo campionare da p_θ , il modello è difficile da usare come generatore.

Apprendere l'energia

Dato un dataset $\mathcal{D} = \{x^{(1)}, \dots, x^{(n)}\}$, la log-likelihood è $\ell(\theta) = \sum_{i=1}^n \log p_{\theta}(x^{(i)})$.

Poiché $\log p_{\theta}(x) = -E_{\theta}(x) - \log Z_{\theta}$, abbiamo

$$\ell(\theta) = -\sum_{i=1}^n E_{\theta}(x^{(i)}) - n \log Z_{\theta}.$$

Il primo termine abbassa l'energia dei dati.

Il secondo impedisce di abbassare tutte le energie insieme.

Dati contro modello

Il gradiente ha la struttura schematica

$$\nabla_{\theta} \ell(\theta) = - \sum_i \nabla_{\theta} E_{\theta}(x^{(i)}) + n \mathbb{E}_{p_{\theta}} [\nabla_{\theta} E_{\theta}(X)] .$$

Interpretazione:

- ▶ termine sui dati: rendere i dati più probabili;
- ▶ termine sul modello: correggere ciò che il modello genera.

Apprendere significa confrontare dati osservati e configurazioni prodotte dal modello.

4. Hopfield networks

Memoria associativa

Una rete di Hopfield è un modello di memoria associativa.

Non archivia un pattern in un indirizzo preciso.

Distribuisce la memoria nei pesi di interazione tra unità.

Compito tipico:

pattern corrotto $\longrightarrow$ pattern memorizzato.

La rete completa o corregge configurazioni iniziali rumorose.

Stati binari e interazioni

Consideriamo N unità binarie:

$$s_i \in \{-1, +1\}, \quad i = 1, \dots, N.$$

Una configurazione è

$$s = (s_1, \dots, s_N).$$

I pesi soddisfano di solito $J_{ij} = J_{ji}$, $J_{ii} = 0$.

La simmetria consente di definire un'energia "conservativa" (path independent).

Energia di Hopfield

La funzione energia è

$$E(s) = -\frac{1}{2} \sum_{i,j} J_{ij} s_i s_j - \sum_i h_i s_i.$$

Senza bias (in fisica *campo esterno*):

$$E(s) = -\frac{1}{2} \sum_{i,j} J_{ij} s_i s_j.$$

La dinamica aggiorna localmente gli stati in modo da ridurre, o almeno non aumentare, l'energia.

Campo locale

Il campo locale sull'unità i è

$$H_i(s) = \sum_j J_{ij}s_j + h_i.$$

Regola deterministica:

$$s_i \leftarrow \text{sign } H_i(s).$$

Se $H_i > 0$, si favorisce $s_i = +1$.

Se $H_i < 0$, si favorisce $s_i = -1$.

Ogni unità si allinea al campo generato dalle altre.

Aggiornamento asincrono

Schema essenziale:

scegli una configurazione iniziale s

ripeti:

 scegli un indice i

 calcola $H_i(s)$

 poni $s_i \leftarrow \text{sign } H_i(s)$

fino a convergenza

Con pesi simmetrici e aggiornamento asincrono, l'energia non aumenta.

Quindi la dinamica converge verso una configurazione stabile.

L'energia agisce come funzione di Lyapunov.

Attrattori e memorie

Una configurazione stabile soddisfa

$$s_i = \text{sign} \left(\sum_j J_{ij} s_j + h_i \right) \quad \forall i.$$

Le configurazioni stabili sono attrattori.

Per memorizzare pattern

$$\xi^\mu = (\xi_1^\mu, \dots, \xi_N^\mu), \quad \mu = 1, \dots, P,$$

si scelgono i pesi in modo che questi pattern diventino attrattori.

Regola di Hebb

Una scelta classica è

$$J_{ij} = \frac{1}{N} \sum_{\mu=1}^P \xi_i^{\mu} \xi_j^{\mu}, \quad i \neq j,$$

con

$$J_{ii} = 0.$$

Interpretazione:

- ▶ unità spesso concordi $\rightarrow$ peso positivo;
- ▶ unità spesso discordi $\rightarrow$ peso negativo.

Le correlazioni nei pattern vengono incorporate nelle interazioni.

Memorie spurie e capacità

Le reti di Hopfield possono generare attrattori non voluti.

Sono le **memorie spurie**.

Origine:

- ▶ combinazioni dei pattern memorizzati;
- ▶ interferenze tra pattern;
- ▶ troppi pattern rispetto a N .

La memoria distribuita non è gratuita.

Gli stessi pesi devono codificare molti pattern e possono produrre strutture collettive inattese.

Ponte verso Boltzmann Machines

Hopfield usa un'energia, ma nella forma classica non è un modello generativo probabilistico.

- ▶ dinamica deterministica;
- ▶ convergenza verso attrattori;
- ▶ obiettivo: recupero di memorie.

Per ottenere un modello probabilistico si introducono aggiornamenti stocastici.

Da

$$s_i = \text{sign } H_i(s)$$

passiamo a probabilità condizionate per i valori di s_i .

5. Boltzmann Machines

Dalla memoria alla distribuzione

Una Boltzmann Machine conserva:

- ▶ variabili binarie;
- ▶ interazioni;
- ▶ funzione energia.

Ma cambia interpretazione:

$$p(s) = \frac{e^{-E(s)}}{Z}.$$

Gli stati non sono solo attrattori, sono campioni da una distribuzione.

Una memoria associativa recupera un pattern.

Una Boltzmann Machine genera configurazioni plausibili.

Variabili visibili e nascoste

Distinguiamo:

- ▶ variabili visibili v : osservate nei dati;
- ▶ variabili nascoste h : fattori latenti.

Lo stato completo è

$$s = (v, h).$$

Distribuzione congiunta: $p(v, h) = e^{-E(v, h)} / Z$.

Distribuzione osservabile: $p(v) = \sum_h p(v, h)$.

Il dato visibile somma tutte le spiegazioni latenti compatibili.

Energia generale

Una forma generale contiene bias e interazioni:

$$E(v, h) = - \sum_i b_i v_i - \sum_a c_a h_a - \sum_{i,a} W_{ia} v_i h_a - \frac{1}{2} \sum_{i,j} A_{ij} v_i v_j - \frac{1}{2} \sum_{a,b} B_{ab} h_a h_b.$$

Termini:

- ▶ bias visibili;
- ▶ bias nascosti;
- ▶ interazioni visibile–nascosto;
- ▶ interazioni tra visibili;
- ▶ interazioni tra nascosti.

Restricted Boltzmann Machine

In una RBM restano solo interazioni visibile–nascosto:

$$E(v, h) = - \sum_i b_i v_i - \sum_a c_a h_a - \sum_{i,a} W_{ia} v_i h_a.$$

La struttura è bipartita.

Non ci sono interazioni:

- ▶ tra visibili;
- ▶ tra nascosti.

Conseguenza: le condizionate fattorizzano.

Condizionate nella RBM

Qui v e h sono vettori:

$$v = (v_1, \dots, v_n), \quad h = (h_1, \dots, h_m).$$

Nel caso RBM, le probabilità condizionate si fattorizzano:

$$p(h \mid v) = \prod_a p(h_a \mid v),$$

$$p(v \mid h) = \prod_i p(v_i \mid h).$$

Fissato v , le variabili nascoste sono indipendenti condizionatamente a v .

Fissato h , le variabili visibili sono indipendenti condizionatamente a h .

Forma logistica

Per variabili 0/1:

$$p(h_a = 1 \mid v) = \sigma \left(c_a + \sum_i W_{ia} v_i \right),$$

$$p(v_i = 1 \mid h) = \sigma \left(b_i + \sum_a W_{ia} h_a \right),$$

con

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Queste formule rendono semplice il campionamento a blocchi.

Campionamento alternato

Schema RBM:

inizializza v

ripeti:

 campiona h da $p(h \mid v)$

 campiona v da $p(v \mid h)$

La catena alterna:

$$v^{(0)} \rightarrow h^{(0)} \rightarrow v^{(1)} \rightarrow h^{(1)} \rightarrow \dots$$

Dopo un numero sufficiente di passi, le configurazioni visibili possono essere usate come campioni del modello.

Positive e negative phase

L'apprendimento confronta:

- ▶ ciò che accade sui dati;
- ▶ ciò che il modello genera.

Positive phase

Riduce l'energia delle configurazioni compatibili con i dati.

Negative phase

Aumenta relativamente l'energia delle configurazioni generate troppo facilmente dal modello.

Questa tensione porta al problema computazionale centrale: stimare la fase negativa.

6. Gibbs sampling

Idea generale

Vogliamo campionare da $p(x) = e^{-E(x)}/Z$ con $x = (x_1, \dots, x_N)$.

Invece di campionare direttamente da $p(x_1, \dots, x_N)$, aggiorniamo una variabile alla volta:

$$p(x_i \mid x_{-i}).$$

Gibbs sampling trasforma un problema globale difficile in molti problemi condizionati più semplici.

Condizionate senza Z

La condizionata è

$$p(x_i \mid x_{-i}) = \frac{p(x_i, x_{-i})}{\sum_{x'_i} p(x'_i, x_{-i})}.$$

Usando $p(x) = e^{-E(x)} / Z$:

$$p(x_i \mid x_{-i}) = \frac{e^{-E(x_i, x_{-i})}}{\sum_{x'_i} e^{-E(x'_i, x_{-i})}}.$$

La funzione di partizione globale si cancella.

Il denominatore somma solo sui valori possibili di x_i .

Caso binario

Per $s_i \in \{-1, +1\}$ e

$$E_i(s_i) = -s_i H_i$$

si ottiene

$$p(s_i = +1 \mid s_{-i}) = \frac{1}{1 + e^{-2H_i}}$$

Confronto:

- ▶ Hopfield deterministico: $s_i = \text{sign}(H_i)$;
- ▶ Gibbs: s_i viene campionato con probabilità dipendente da H_i .

Gibbs a blocchi nelle RBM

Nelle RBM:

$$p(h \mid v) = \prod_a p(h_a \mid v),$$

$$p(v \mid h) = \prod_i p(v_i \mid h).$$

Quindi possiamo aggiornare blocchi interi:

campiona tutti gli h_a dato v

campiona tutti i v_i dato h

Questo rende le RBM più trattabili delle Boltzmann Machines generali.

Burn-in, autocorrelazione, mixing

Gibbs produce una catena di Markov.

I campioni successivi non sono indipendenti.

Tre concetti pratici:

- ▶ **burn-in**: scartare la fase iniziale (*termalizzazione*);
- ▶ **autocorrelazione**: campioni vicini sono simili;
- ▶ **mixing**: capacità della catena di esplorare regioni diverse.

Se il mixing è lento, la negative phase viene stimata male.

Perché serve nell'apprendimento

Gibbs sampling compare in due modi:

1. generare campioni dal modello;
2. stimare la *negative phase*.

Il problema è che una stima corretta richiederebbe catene lunghe.

La *contrastive divergence* nasce come scorciatoia:

- ▶ inizializza la catena sui dati;
- ▶ esegue pochi passi di Gibbs;
- ▶ usa le ricostruzioni come confronto approssimato.

7. Apprendimento e problema di Z

Log-likelihood energetica

Per un dataset $\mathcal{D} = \{x^{(1)}, \dots, x^{(n)}\}$ la log-likelihood è

$$\ell(\theta) = \sum_{i=1}^n \log p_{\theta}(x^{(i)}).$$

Poiché $\log p_{\theta}(x) = -E_{\theta}(x) - \log Z_{\theta}$, segue

$$\ell(\theta) = -\sum_{i=1}^n E_{\theta}(x^{(i)}) - n \log Z_{\theta}.$$

Perché $\log Z_\theta$ è necessario

Senza il termine di normalizzazione, basterebbe abbassare tutte le energie.

Ma abbassare tutte le energie della stessa quantità non cambia la distribuzione normalizzata.

$\log Z_\theta$ rende l'apprendimento probabilistico:

- ▶ non basta rendere i dati meno energetici;
- ▶ bisogna renderli più probabili rispetto alle alternative.

Aumentare la probabilità di alcuni stati significa redistribuire massa di probabilità.

Gradiente

Per un singolo dato:

$$\nabla_{\theta} \log p_{\theta}(x) = -\nabla_{\theta} E_{\theta}(x) + \mathbb{E}_{p_{\theta}} [\nabla_{\theta} E_{\theta}] .$$

Per il dataset:

$$\nabla_{\theta} \ell(\theta) = -\sum_{i=1}^n \nabla_{\theta} E_{\theta}(x^{(i)}) + n \mathbb{E}_{p_{\theta}} [\nabla_{\theta} E_{\theta}] .$$

È il confronto tra dati e modello.

Medie dati e medie modello

Definiamo

$$\mathbb{E}_{data}[f(X)] = \frac{1}{n} \sum_{i=1}^n f(x^{(i)}).$$

Allora

$$\frac{1}{n} \nabla_{\theta} \ell(\theta) = -\mathbb{E}_{data} [\nabla_{\theta} E_{\theta}(X)] + \mathbb{E}_{p_{\theta}} [\nabla_{\theta} E_{\theta}].$$

La prima media è facile: abbiamo i dati.

La seconda è difficile: richiede campioni dal modello.

Energia lineare nelle feature

Se

$$E_{\theta}(x) = - \sum_k \theta_k f_k(x),$$

allora

$$\frac{1}{n} \frac{\partial \ell}{\partial \theta_k} = \mathbb{E}_{data}[f_k(X)] - \mathbb{E}_{p_{\theta}}[f_k].$$

L'apprendimento spinge verso

$$\mathbb{E}_{p_{\theta}}[f_k(Y)] \approx \mathbb{E}_{data}[f_k(X)].$$

Interpretazione: matching tra statistiche osservate e statistiche generate.

Variabili nascoste e free energy

Per variabili visibili v e nascoste h :

$$p_{\theta}(v) = \sum_h p_{\theta}(v, h).$$

Definiamo la free energy sommando le “spiegazioni latenti”:

$$F_{\theta}(v) = -\log \sum_h e^{-E_{\theta}(v, h)}.$$

Allora

$$p_{\theta}(v) = e^{-F_{\theta}(v)} / Z_{\theta}.$$

La free energy è l'energia efficace delle variabili visibili.

Il collo di bottiglia

Il termine difficile da calcolare è

$$\mathbb{E}_{p_\theta}[g] = \sum_y g(y) p_\theta(y).$$

Se lo spazio è grande, la somma è impraticabile.

La stimiamo con campioni:

$$\mathbb{E}_{p_\theta}[g] \approx \frac{1}{M} \sum_{m=1}^M g(y^{(m)}), \quad Y^{(m)} \sim p_\theta.$$

Il simbolo $\sim$ significa “è distribuito secondo”.

Il problema dell'apprendimento diventa un problema di campionamento.

Tre possibilità:

1. **catene lunghe**: più accurate, ma costose;
2. **catene persistenti**: non ripartono da zero a ogni aggiornamento;
3. **catene brevi inizializzate sui dati**: idea alla base della contrastive divergence.

La contrastive divergence non è campionamento esatto.

È un'approssimazione pratica del gradiente quando la negative phase è troppo costosa.

8. Contrastive divergence

Problema pratico

Il gradiente esatto richiede:

$$\mathbb{E}_{data}[\cdot] \quad \text{e} \quad \mathbb{E}_{p_{\theta}}[\cdot].$$

La media sui dati è disponibile.

La media sul modello richiede campioni da p_{θ} .

Se campionare fino all'equilibrio è troppo costoso, serve un'approssimazione.

La contrastive divergence sostituisce la *negative phase* esatta con una *negative phase* “breve”.

Idea di base

- ▶ Si parte da un dato reale $x^{(0)}$
- ▶ Si fanno pochi passi di Gibbs: $x^{(0)} \rightarrow x^{(1)} \rightarrow \dots \rightarrow x^{(k)}$

Si confrontano:

dato reale VS ricostruzione dopo pochi passi.

Il modello viene aggiornato per rendere i dati più probabili delle ricostruzioni indesiderate.

Schema:

per ogni dato $\hat{x}(0)$:

inizializza la catena in $\hat{x}(0)$

esegui k passi di Gibbs sampling

ottieni $\hat{x}(k)$

aggiorna i parametri confrontando $\hat{x}(0)$ e $\hat{x}(k)$

Nel caso CD-1 per una RBM:

$$v^{(0)} \rightarrow h^{(0)} \rightarrow v^{(1)} \rightarrow h^{(1)}.$$

CD-1 è economica, ma più approssimata.

Aggiornamento dei pesi

Per una RBM, il parametro W_{ia} è associato al prodotto $v_i h_a$.

L'aggiornamento ideale confronta

$$\langle v_i h_a \rangle_{data} \quad \text{e} \quad \langle v_i h_a \rangle_{model}.$$

CD-k sostituisce la media del modello con la media sulle ricostruzioni:

$$\Delta W_{ia} \propto \langle v_i h_a \rangle_{data} - \langle v_i h_a \rangle_{CD-k}.$$

CD-1 nelle RBM

Dato $v^{(0)}$:

1. campiona $h^{(0)} \sim p(h \mid v^{(0)})$
2. ricostruisci $v^{(1)} \sim p(v \mid h^{(0)})$
3. campiona $h^{(1)} \sim p(h \mid v^{(1)})$
4. confronta le correlazioni $v^{(0)}h^{(0)}$ e $v^{(1)}h^{(1)}$.

Perché partire dai dati

Partire dai dati inizializza la catena in una regione plausibile.

Se il modello è buono, pochi passi producono ricostruzioni simili ai dati.

Se il modello è cattivo, le ricostruzioni si allontanano e forniscono un segnale di correzione.

CD-k osserva il comportamento locale del modello vicino alla distribuzione empirica.

Non esplora necessariamente tutto lo spazio.

La contrastive divergence:

- ▶ non fornisce in generale il gradiente esatto della likelihood;
- ▶ può essere distorta se k è piccolo;
- ▶ può fallire se il mixing è lento;
- ▶ può migliorare le ricostruzioni senza stimare bene la probabilità normalizzata.

È una procedura pratica, non una soluzione esatta.

Persistent contrastive divergence

Una variante mantiene catene persistenti durante l'apprendimento.

Invece di ripartire dai dati:

- ▶ le catene vengono conservate;
- ▶ a ogni aggiornamento fanno pochi passi;
- ▶ seguono gradualmente la distribuzione del modello.

L'obiettivo è stimare meglio la negative phase.

Anche qui il limite resta il mixing della catena.

9. Hamiltonian Monte Carlo

Spazi continui

Gibbs è naturale per variabili discrete o aggiornabili per blocchi.

Per variabili continue ad alta dimensione, piccoli passi casuali possono essere inefficienti.

HMC usa gradienti per costruire proposte lunghe ma plausibili.

Esempi:

- ▶ parametri continui;
- ▶ variabili latenti continue;
- ▶ modelli bayesiani;
- ▶ distribuzioni definite da negative log-likelihood o negative log-posterior.

Target ed energia potenziale

- ▶ Vogliamo campionare $\pi(q)$, $q \in \mathbb{R}^d$.
- ▶ Spesso conosciamo solo $\pi(q) \propto e^{-U(q)}$.

Definiamo

$$U(q) = -\log \pi(q) + \text{costante}.$$

$U(q)$ è l'energia potenziale.

La costante non conta per gradienti e rapporti.

Momento ausiliario

Introduciamo un *momento* $p \in \mathbb{R}^d$. (qui p è momento “*massa* $\times$ *velocità*”, non probabilità).

- ▶ Energia cinetica $K(p) = \frac{1}{2}p^T M^{-1}p$
- ▶ Hamiltoniana $H(q, p) = U(q) + K(p)$

Distribuzione congiunta:

$$\pi(q, p) \propto e^{-H(q, p)}$$

Marginalizzando su p , si recupera la distribuzione target su q .

Dinamica hamiltoniana

Le equazioni sono

$$\frac{dq}{dt} = \frac{\partial H}{\partial p} \quad , \quad \frac{dp}{dt} = -\frac{\partial H}{\partial q}.$$

Con energia cinetica quadratica:

$$\frac{dq}{dt} = M^{-1}p \quad , \quad \frac{dp}{dt} = -\nabla U(q)$$

La dinamica usa il gradiente per muovere il punto nello spazio.

Leapfrog

Un passo leapfrog con passo ϵ :

$$p \leftarrow p - \frac{\epsilon}{2} \nabla U(q), \quad q \leftarrow q + \epsilon M^{-1} p, \quad p \leftarrow p - \frac{\epsilon}{2} \nabla U(q).$$

Ripetendo L passi si ottiene una proposta (q', p') .

Leapfrog è reversibile e preserva il volume dello spazio delle fasi.

L'errore sull'Hamiltoniana viene corretto con accettazione Metropolis.

Accettazione

La proposta viene accettata con probabilità

$$\alpha = \min\{1, \exp[-H(q', p') + H(q, p)]\}.$$

Se l'integrazione conserva quasi l'Hamiltoniana,

$$H(q', p') \approx H(q, p),$$

allora α è vicina a uno.

HMC può quindi proporre mosse lunghe con alta probabilità di accettazione.

Schema HMC

scegli uno stato iniziale q

ripeti:

 campiona un momento p da una gaussiana

 simula L passi leapfrog

 ottieni una proposta (q', p')

 accetta o rifiuta q'

A ogni iterazione vale:

$$p \sim \mathcal{N}(0, M).$$

La sequenza finale dei campioni è la sequenza delle posizioni q .

I momenti sono ausiliari.

HMC ed energy-based models

Se $p_\theta(q) = e^{-E_\theta(q)} / Z_\theta$

- ▶ poniamo $U(q) = E_\theta(q)$
- ▶ il gradiente richiesto è $\nabla U(q) = \nabla E_\theta(q)$

La normalizzazione non compare nel gradiente:

$$\nabla_q \log p_\theta(q) = -\nabla_q E_\theta(q).$$

HMC richiede la log-densità non normalizzata e il suo gradiente.

Gibbs vs HMC

Metodo	Naturale quando	Usa
Gibbs sampling	variabili discrete o blocchi condizionati	distribuzioni condizionate
HMC	variabili continue differenziabili	gradienti e dinamica ausiliaria

Entrambi campionano da distribuzioni complesse definite implicitamente.

Ma sfruttano strutture diverse del problema.

Limiti di HMC

HMC richiede:

- ▶ variabili continue;
- ▶ energia differenziabile;
- ▶ gradienti calcolabili;
- ▶ scelta adeguata di passo, lunghezza e massa.

Può essere difficile con:

- ▶ geometrie complicate;
- ▶ code forti;
- ▶ curvature molto diverse;
- ▶ regioni strette;
- ▶ gradienti costosi.

Quando funziona, produce campioni meno correlati di molte dinamiche locali.

10. Sintesi finale

Ruolo dei metodi

Oggetto	Ruolo	Idea chiave
EBM	modello implicito	un'energia definisce una distribuzione
Hopfield	memoria associativa	attrattori come pattern memorizzati
Boltzmann Machine	modello generativo	campioni con peso di Boltzmann
RBM	BM bipartita	condizionate semplici
Gibbs	campionamento discreto	aggiornare da condizionate
CD	apprendimento approssimato	dati vs ricostruzioni
HMC	campionamento continuo	gradienti e dinamica

Errori concettuali da evitare

- ▶ Energia bassa non significa probabilità uno.
- ▶ Generare non significa minimizzare.
- ▶ Una probabilità non normalizzata non è ancora una probabilità.
- ▶ La funzione di partizione non è un dettaglio tecnico.
- ▶ Una ricostruzione CD non è un campione indipendente dal modello.

Il punto chiave è distinguere configurazioni ottime, configurazioni tipiche e configurazioni generate.

Applicazioni: una carrellata

Lo stesso linguaggio compare in molti campi.

Campo	Configurazione	Energia/costo	Uso
Fisica	microstato	energia	equilibrio
ML	dato/latente	energy/loss	generazione
Bayes	parametri	negative log-posterior	incertezza
Neuroscienze	pattern	energia attrattiva	memoria
Biologia	sequenza/conformazione	score	compatibilità
Reti	grafo/partizione	score negativo	ensemble
Scienze sociali	scelta/stato/rete	disutilità/distanza	scenari
Visione	immagine/segmentazione	data term + prior	ricostruzione

Chiusura

Una funzione energia può essere usata per:

1. cercare configurazioni a bassa energia;
2. campionare configurazioni con probabilità proporzionale a $e^{-E(x)}$;
3. apprendere un modello generativo dai dati.

La stessa struttura matematica collega:

ottimizzare, campionare, generare.

Questo è il ponte tra meccanica statistica, inferenza, machine learning e modellizzazione computazionale.