

Project: Reti di reazioni e algoritmo di Gillespie

catene di Markov a tempo continuo, chimica stocastica e
simulazione esatta di eventi

1. Obiettivi della dispensa

Questa dispensa introduce le **reaction networks** stocastiche e l'algoritmo di **Gillespie** come caso di studio per un corso di metodi computazionali per modelli stocastici.

Gli obiettivi sono sei:

1. formalizzare una rete di reazioni come **catena di Markov a tempo continuo** su uno spazio discreto di stati;
2. distinguere chiaramente tra descrizione discreta stocastica, descrizione mean-field deterministica e, quando appropriato, limite diffusivo;
3. introdurre il concetto di **propensity** come tasso di occorrenza degli eventi elementari;
4. spiegare perché l'algoritmo di Gillespie fornisca una simulazione esatta della CTMC sottostante;
5. usare il formalismo per trattare esempi di nascita–morte, contagio, espressione genica e piccole reti biochimiche;
6. discutere quando una descrizione continua via ODE o SDE diventi insufficiente e quando invece rappresenti una buona approssimazione.

Dal punto di vista del corso, questo progetto è particolarmente importante perché introduce in modo molto esplicito un'intera classe di modelli che non coincide né con le equazioni differenziali ordinarie, né con le SDE, né con le simulazioni a passo fisso. Qui il sistema evolve per **salti discreti** e i tempi tra gli eventi sono essi stessi variabili aleatorie. È quindi uno dei luoghi migliori in cui insegnare davvero che cosa sia una dinamica event-driven su spazio discreto.

2. Motivazione generale

Molti sistemi reali non evolvono in modo continuo e regolare, ma attraverso eventi elementari che cambiano bruscamente lo stato del sistema.

Esempi tipici sono:

- una molecola che viene prodotta o degradata;
- un individuo che nasce o muore;
- un infetto che contagia un suscettibile;
- una proteina che si lega a un sito regolatorio;
- una preda che viene consumata da un predatore;
- una particella che subisce una trasformazione chimica discreta.

Quando le quantità in gioco sono grandi, questi sistemi possono spesso essere ben approssimati da equazioni differenziali continue. Ma quando i numeri sono piccoli, le fluttuazioni relative diventano importanti e la descrizione deterministica può essere fuorviante. In questi casi bisogna modellare esplicitamente:

- i salti discreti negli stati;
- i tempi casuali tra un evento e il successivo;
- la variabilità tra traiettorie diverse.

Questa è precisamente la situazione in cui entrano in gioco le reaction networks stocastiche.

3. Campi di applicazione

Il formalismo è nato in chimica stocastica, ma oggi è usato in contesti molto più ampi.

3.1 Reazioni chimiche elementari


Quando il numero di molecole non è molto grande, il numero di collisioni e trasformazioni elementari fluttua in modo significativo. In questo caso il modello deterministico a concentrazioni può perdere una parte importante della fenomenologia.

3.2 Dinamiche di nascita e morte

Un processo di nascita–morte è una delle reti di reazione più semplici possibili. Proprio per questo è un ottimo punto di ingresso per il formalismo generale.

3.3 Epidemiologia in popolazioni finite

Un contagio elementare come



o la guarigione



si scrivono naturalmente come reazioni. Quando la popolazione è piccola o il numero di infetti è basso, la descrizione stocastica è spesso più appropriata di una ODE media.

3.4 Espressione genica e biologia molecolare

Produzione e degradazione di mRNA e proteine, attivazione e disattivazione di geni, binding e unbinding di fattori regolatori sono tutti esempi tipici in cui la natura discreta delle molecole conta in modo essenziale.

3.5 Ecologia di piccole popolazioni

In sistemi con pochi individui, gli eventi di nascita, morte e interazione sono intrinsecamente discreti e il rischio di estinzione stocastica non è catturato da una descrizione puramente deterministica.

4. Reti di reazioni: formalismo generale

4.1 Stato del sistema

Consideriamo n specie o tipi di entità. Lo stato del sistema al tempo t è un vettore intero non negativo

$$X(t) = (X_1(t), \dots, X_n(t)),$$

dove $X_i(t)$ è il numero di individui o molecole della specie i .

4.2 Reazioni elementari

Supponiamo di avere R reazioni elementari. Ogni reazione r è caratterizzata da:

- un **vettore di variazione** o stoichiometria

$$\nu_r,$$


che specifica come cambia lo stato quando la reazione avviene;

- una **propensity**

$$a_r(X),$$

che rappresenta il tasso con cui la reazione r avviene quando il sistema si trova nello stato X .

Quando la reazione r si verifica, lo stato viene aggiornato secondo



4.3 Significato della propensity

La propensity $a_r(X)$ ha una interpretazione probabilistica molto precisa:

$$a_r(X), dt$$


è, al primo ordine in dt , la probabilità che la reazione r avvenga nell'intervallo di tempo $(t, t + dt]$ dato che il sistema è nello stato X al tempo t .

Questo è il punto centrale dell'intero formalismo. Le reaction networks non sono soltanto “regole di aggiornamento”, ma veri processi stocastici a tempo continuo definiti da tassi locali di transizione.

5. Esempi fondamentali

5.1 Processo di nascita–morte

Il caso più semplice è un'unica specie X con due reazioni:




Qui:

- la nascita avviene con tasso costante λ ;
- la morte avviene con tasso proporzionale al numero attuale di individui.

Questo è un eccellente esempio base perché si può trattare sia analiticamente sia computazionalmente.

5.2 Modello SIS minimale come rete di reazioni

Un contagio SIS può essere scritto come:



La prima reazione rappresenta l'infezione di un suscettibile da parte di un infetto, la seconda la guarigione.

5.3 Espressione genica elementare

Una rete minima può includere:

- produzione di mRNA;
- degradazione di mRNA;
- produzione di proteina da mRNA;
- degradazione di proteina.

Questo caso è importante perché mostra come fluttuazioni stocastiche piccole a livello molecolare possano generare forte variabilità tra cellule.

5.4 Predatore–preda discreto

Si possono rappresentare in forma stocastica:

- nascita della preda;
- consumo della preda da parte del predatore;
- morte del predatore.

Questo fornisce un ponte naturale verso i modelli ecologici.

6. CTMC e master equation

6.1 Natura markoviana della dinamica

Una reaction network stocastica definisce una **catena di Markov a tempo continuo**. Lo stato futuro dipende soltanto dallo stato attuale e non dall'intera storia passata, ma i tempi di transizione sono casuali.

6.2 Tempo di attesa tra eventi

Se il sistema si trova nello stato X , il tasso totale di uscita è

$$a_0(X) = \sum_{r=1}^R a_r(X).$$

Il tempo fino al prossimo evento è distribuito come una variabile esponenziale:

$$\tau \sim \text{Exp}(a_0(X)).$$

Questa proprietà è il cuore dell'algoritmo di Gillespie.

6.3 Master equation

Se indichiamo con $P(X, t)$ la probabilità di essere nello stato X al tempo t , allora la sua evoluzione è governata da una **master equation**. In forma generale, il bilancio è dato da:

- probabilità che entra nello stato X da stati vicini;
- probabilità che esce dallo stato X a causa delle reazioni possibili.

Non è necessario sviluppare qui tutta la teoria generale, ma è importante che gli studenti capiscano che il processo microscopico possiede una descrizione probabilistica esatta a livello di distribuzione.

7. L'algoritmo di Gillespie

7.1 Idea di base

L'algoritmo di Gillespie, o **Stochastic Simulation Algorithm** (SSA), genera una traiettoria esatta del processo stocastico senza introdurre errori di discretizzazione temporale.

A stato dato X :

1. si calcolano tutte le propensities $a_r(X)$;
2. si somma

$$a_0(X) = \sum_r a_r(X);$$

3. si estrae il tempo al prossimo evento

$$\tau \sim \text{Exp}(a_0);$$

4. si sceglie quale reazione avviene con probabilità proporzionale a

$$\frac{a_r(X)}{a_0(X)};$$

5. si aggiorna lo stato secondo il vettore stoichiometrico corrispondente.

7.2 Perché è esatto

Il metodo è esatto perché riproduce esattamente:

- la distribuzione del tempo al prossimo evento;
- la distribuzione condizionata del tipo di evento dato che un evento avviene.

In altre parole, non approssima la CTMC con piccoli passi temporali, ma campiona direttamente la sua dinamica reale.

7.3 Confronto con una simulazione a passo fisso

Una simulazione a passo fisso impone un reticolo temporale artificiale e può commettere errori se in un singolo intervallo avvengono:

- più eventi di quelli previsti;
- eventi in un ordine scorretto;
- salti con probabilità non ben approssimata.

Gillespie evita questo problema alla radice, perché il tempo stesso viene simulato come variabile casuale.

8. Mean-field, ODE e limite continuo

Uno dei punti didatticamente più importanti del progetto è il confronto tra diversi livelli descrittivi.

8.1 Descrizione microscopica discreta

Questa è la descrizione esatta quando lo stato è un vettore intero e gli eventi sono discreti. È il livello naturale di Gillespie.

8.2 Equazioni mean-field

Se i numeri sono grandi e le fluttuazioni relative piccole, le medie possono essere approssimate da equazioni differenziali ordinarie.

Per esempio, nel processo di nascita–morte:

$$\frac{d}{dt}\mathbb{E}[X] \approx \lambda - \mu X.$$

8.3 Limite diffusivo

In alcuni casi, con opportune riscalature, la dinamica discreta può essere approssimata da una SDE. Questo fornisce un ponte con i modelli continui già presenti nel corso.

8.4 Quando la descrizione continua fallisce

La descrizione deterministica diventa problematica quando:

- il numero di individui o molecole è piccolo;
- il sistema è vicino a uno stato assorbente;
- le fluttuazioni relative sono grandi;
- gli eventi rari dominano la fenomenologia.

9. Osservabili da misurare

Per trasformare il progetto in un vero case study computazionale conviene introdurre alcune osservabili standard.

9.1 Traiettorie individuali

Le singole traiettorie mostrano in modo molto chiaro la natura a salti della dinamica.

9.2 Medie e varianze di ensemble

Ripetendo la simulazione su molte realizzazioni indipendenti si possono stimare:

- medie temporali;
- varianze;
- covarianze tra specie.

9.3 Distribuzioni stazionarie empiriche

Se il sistema ammette un regime stazionario, si può stimare empiricamente la distribuzione degli stati.

9.4 Tempi di estinzione o first-passage

Per sistemi con stati assorbenti o soglie di interesse, si possono misurare tempi di estinzione, tempi di raggiungimento e probabilità di hitting.

9.5 Confronto con le ODE mean-field

È molto utile confrontare:

- la media di ensemble delle traiettorie stocastiche;
- la soluzione delle equazioni deterministiche corrispondenti.

10. Domande scientifiche che il progetto permette di studiare

1. Quando la descrizione deterministica fallisce in modo qualitativo?
2. Quanto sono grandi le fluttuazioni finite-size?
3. In quali regimi la media di ensemble segue bene la dinamica mean-field?
4. Come cambia il comportamento al crescere della scala di popolazione?
5. Perché Gillespie è esatto rispetto alla CTMC sottostante?
6. In che senso tempi di estinzione o eventi rari non sono catturati bene da una ODE media?
7. Quali differenze emergono tra singole traiettorie e comportamento medio?

11. Pseudocodice del metodo

11.1 Input

- numero di specie n
- lista delle reazioni
- vettori stechiometrici ν_r
- propensities $a_r(X)$
- stato iniziale $X(0)$
- tempo finale T
- numero di realizzazioni indipendenti R

11.2 Pseudocodice: algoritmo di Gillespie

```
Inizializza lo stato  $X = X(0)$ 
Poni  $t = 0$ 

Finché  $t < T$ :
    calcola tutte le propensities  $a_r(X)$ 
    calcola  $a_0 = \text{somma}_r a_r(X)$ 

    se  $a_0 = 0$ :
        termina la simulazione

    estrai  $u_1, u_2 \sim U(0,1)$ 
    calcola  $\tau = -(1/a_0) * \log(u_1)$ 
    poni  $t \leftarrow t + \tau$ 

    scegli la reazione  $r$  tale che
         $\text{somma}_{\{k \leq r-1\}} a_k < u_2 * a_0 \leq \text{somma}_{\{k \leq r\}} a_k$ 

    aggiorna lo stato:
         $X \leftarrow X + \nu_r$ 

    registra eventualmente:
        - stato  $X$ 
        - tempo  $t$ 
        - osservabili derivate
```

11.3 Osservazione implementativa

Il punto importante è che il tempo non viene aggiornato in modo uniforme, ma tramite salti casuali di ampiezza variabile. Questa è la caratteristica che rende il metodo qualitativamente diverso da un integratore a passo fisso.

12. Schema del laboratorio

12.1 Laboratorio 1 – Birth–death process

Obiettivo

Capire la logica del formalismo su un esempio minimale.

Attività

1. implementare il processo di nascita–morte con Gillespie;
2. simulare molte traiettorie indipendenti;
3. confrontare media e varianza con le previsioni teoriche;

4. osservare la differenza tra singole traiettorie e andamento medio.

Domande guida

- Le traiettorie individuali sono molto fluttuanti?
- La media di ensemble segue la soluzione mean-field?
- Come cambia la variabilità relativa al crescere della popolazione media?

12.2 Laboratorio 2 – SIS minimale come reaction network

Obiettivo

Usare Gillespie su un piccolo modello epidemico discreto.

Attività

1. implementare le reazioni $S + I \rightarrow 2I$ e $I \rightarrow S$;
2. simulare molte realizzazioni per diversi parametri;
3. misurare numero medio di infetti e tempi di estinzione;
4. confrontare con la corrispondente descrizione deterministica.

Domande guida

- Le estinzioni stocastiche compaiono anche dove la ODE predice uno stato endemico?
- Quanto conta la dimensione totale della popolazione?
- Le fluttuazioni diventano piccole solo per popolazioni grandi?

12.3 Laboratorio 3 – Gene expression o piccola rete biochimica

Obiettivo

Mostrare che la discrezione molecolare può produrre grande variabilità tra traiettorie.

Attività

1. implementare una piccola rete di produzione e degradazione di mRNA e proteine;
2. simulare molte cellule indipendenti;
3. misurare medie, varianze e distribuzioni stazionarie;
4. discutere il significato biologico delle fluttuazioni.

Domande guida

- Due traiettorie con stessi parametri possono apparire molto diverse?
- La distribuzione stazionaria è larga o stretta?
- La descrizione deterministica perde la variabilità essenziale del sistema?

13. Estensioni possibili

Una volta implementato Gillespie nella sua forma base, si possono considerare diverse estensioni.

13.1 Tau-leaping

Per accelerare le simulazioni, si può usare una approssimazione in cui si fanno avanzare più eventi insieme in piccoli intervalli temporali.

13.2 Reazioni reversibili e detailed balance

Si possono introdurre reti semplici reversibili per discutere il rapporto tra dinamica stocastica, stati stazionari e equilibrio.

13.3 Collegamento con SDE

È istruttivo confrontare le traiettorie ottenute con Gillespie con una approssimazione diffusiva-limit integrata tramite Euler–Maruyama.

13.4 Event-driven oltre la chimica

Si può discutere il collegamento con:

- queueing;
- Hawkes;
- contact process;
- modelli epidemici finiti.

13.5 La master equation e la sua verifica numerica

Significato generale della master equation

Se indichiamo con $P(X, t)$ la probabilità che il sistema si trovi nello stato discreto X al tempo t , allora la sua evoluzione è governata da una **master equation**, cioè da una equazione di bilancio delle probabilità.

L'idea è semplice: la probabilità nello stato X può cambiare per due ragioni.

- probabilità che entra in X da altri stati compatibili con una singola reazione;

- probabilità che esce da X perché, partendo da X , avviene una delle reazioni possibili.

Per ogni reazione r , se il salto associato è ν_r , allora uno stato $X - \nu_r$ può entrare in X attraverso la reazione r , mentre da X si può uscire verso $X + \nu_r$ con la stessa reazione.

Forma generale

La forma standard è

$$\frac{d}{dt}P(X, t) = \sum_{r=1}^R [a_r(X - \nu_r)P(X - \nu_r, t) - a_r(X)P(X, t)],$$

dove:

- il primo termine rappresenta i contributi entranti nello stato X ;
- il secondo termine rappresenta i contributi uscenti dallo stato X .

Questa è la forma fondamentale della dinamica probabilistica esatta del sistema.

Esempio: birth–death process

Nel caso di una sola specie $X \in \{0, 1, 2, \dots\}$ con:

$$X \rightarrow X + 1 \quad \text{con tasso } \lambda,$$

$$X \rightarrow X - 1 \quad \text{con tasso } \mu X,$$

la probabilità $P_n(t) = \Pr[X(t) = n]$ soddisfa

$$\frac{d}{dt}P_n(t) = \lambda P_{n-1}(t) + \mu(n+1)P_{n+1}(t) - (\lambda + \mu n)P_n(t),$$

per $n \geq 1$, mentre per $n = 0$ si ha

$$\frac{d}{dt}P_0(t) = \mu P_1(t) - \lambda P_0(t).$$

Questo esempio è molto istruttivo perché mostra in modo completamente esplicito il significato dei termini entranti e uscenti.

Perché la master equation è importante

Dal punto di vista del corso, la master equation è importante per almeno tre ragioni.

Primo, rende esplicito che il modello non è solo una procedura di simulazione, ma una dinamica probabilistica ben definita.

Secondo, chiarisce la differenza tra:

- equazione per la distribuzione di probabilità;
- equazione per la media;
- traiettoria stocastica individuale.

Terzo, permette di spiegare in modo rigoroso in che senso Gillespie sia un simulatore esatto della CTMC: esso non approssima la master equation, ma genera traiettorie la cui distribuzione è esattamente quella descritta da essa.

Verifica numerica della master equation

Per un modello semplice come il birth–death process, una procedura ragionevole di verifica è la seguente.

1. Si fissano alcuni tempi di osservazione $t_1, t_2, \dots$
2. Si eseguono molte simulazioni indipendenti con Gillespie.
3. Per ogni tempo t_k , si costruisce la distribuzione empirica degli stati.
4. In parallelo, si integra numericamente la master equation su uno spazio degli stati troncato.
5. Si confrontano le due distribuzioni, per esempio tramite:
 - norma L^1 ;
 - errore quadratico;
 - confronto grafico punto per punto.

Questa attività è molto preziosa, perché mostra agli studenti che il simulatore stocastico non è una scatola nera indipendente dalla teoria, ma uno strumento che realizza concretamente la stessa dinamica descritta dalla master equation.

Domande guida sulla verifica

- Le distribuzioni empiriche convergono alla soluzione della master equation all'aumentare del numero di realizzazioni?
- L'errore è uniforme oppure cresce nelle code della distribuzione?
- È più facile verificare la master equation a livello di media o di distribuzione completa?
- In quali modelli la soluzione esplicita è disponibile, e in quali bisogna usare un'integrazione numerica della master equation?

14. Perché questo è un buon case study per il corso

Questa dispensa è molto adatta a un corso di metodi computazionali per almeno quattro ragioni.

Primo, introduce in modo molto chiaro la nozione di **CTMC su spazio discreto**, che è fondamentale ma spesso poco interiorizzata dagli studenti.

Secondo, insegna una metodologia computazionale molto importante, l'algoritmo di Gillespie, che è uno standard in molti ambiti applicativi.

Terzo, permette di confrontare in modo estremamente concreto tre livelli di descrizione:

- dinamica discreta stocastica;
- dinamica media deterministica;
- eventuale limite diffusive.

Quarto, crea ponti naturali con molti altri progetti del corso:

- con **contact process** ed **epidemie su reti**, perché il contagio può essere scritto come rete di reazioni;
- con **Hawkes**, perché entrambi sono processi a eventi ma con strutture diverse;
- con **queueing**, perché condividono una logica event-driven;
- con le **SDE**, perché offre un contrasto molto pulito tra salti discreti e rumore continuo.

Osservazione finale

Questo progetto è uno dei migliori strumenti didattici per mostrare che il modo in cui si simula un sistema non è un dettaglio tecnico secondario, ma riflette la natura matematica del modello. Se gli eventi sono discreti e i tempi tra eventi sono casuali, la simulazione naturale non è a passo fisso: è proprio questo che Gillespie rende trasparente.